

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное
образовательное учреждение высшего образования
«Московский государственный лингвистический университет»
(ФГБОУ ВО МГЛУ)
Federal State Budgetary Educational Institution of Higher Education
«Moscow State Linguistic University»
(MSLU)

Институт информационных наук
Кафедра международной информационной безопасности
Направление подготовки / специальность: информационная безопасность

Допустить к защите
Заведующий выпускающей кафедрой:
Бонч-Бруевич Андрей Михайлович
_____ 2026 г.

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
на тему

Разработка методических рекомендаций по интеграции технологий
искусственного интеллекта в систему управления информационной
безопасностью

Выполнил:
обучающийся группы 1-22-2 ИИН
Воробьева Евгения Александровна
Руководитель / научный руководитель:
к.т.н., доцент М. Ю. Толстых

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	5
ГЛАВА 1. ТЕОРЕТИКО-АНАЛИТИЧЕСКИЕ ОСНОВЫ ИНТЕГРАЦИИ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА В СИСТЕМУ УПРАВЛЕНИЯ ИНФОРМАЦИОННОЙ БЕЗОПАСНОСТЬЮ	9
1.1 Современные вызовы для систем управления информационной безопасностью и ограничения традиционных систем защиты	9
1.2 Технологии искусственного интеллекта и анализ их применимости для задач информационной безопасности	12
1.2.1 Машинное обучение (Machine Learning)	12
1.2.2 Поведенческий анализ (UEBA)	13
1.2.3 Обработка естественного языка (NLP)	14
1.2.4 Сводный анализ применимости технологий	14
1.3 Анализ рынка решений и кейсов интеграции искусственного интеллекта в информационную безопасность	15
1.3.1 Обзор рынка решений	16
1.3.2 Типичные проблемы и риски внедрения	17
1.3.3 Анализ успешных практик	21
1.4 Выводы по первой главе	23
ГЛАВА 2. РАЗРАБОТКА МЕТОДИЧЕСКИХ РЕКОМЕНДАЦИЙ ПО ИНТЕГРАЦИИ ТЕХНОЛОГИЙ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА В СИСТЕМУ УПРАВЛЕНИЯ ИНФОРМАЦИОННОЙ БЕЗОПАСНОСТЬЮ	24

2.1 Концептуальная модель и этапы интеграции искусственного интеллекта в процессы системы управления информационной безопасностью	24
2.2 Поэтапная методика интеграции технологий искусственного интеллекта в систему управления информационной безопасностью.....	26
2.3 Организационно-кадровое обеспечение внедрения и методы оценки экономической эффективности	32
2.3.1 Организационно-кадровое обеспечение	32
2.3.2 Методы оценки экономической эффективности	34
2.4 Выводы по второй главе	39
ГЛАВА 3. ОЦЕНКА ЭФФЕКТИВНОСТИ МЕТОДИЧЕСКИХ РЕКОМЕНДАЦИЙ	40
3.1 Постановка задачи и описание условий для апробации	40
3.1.1 Характеристика объекта апробации	40
3.1.2 Выбор и обоснование пилотного процесса	41
3.1.3 Источники данных и их подготовка	43
3.1.4 Инструментальные средства проведения апробации	46
3.1.5 Метрики оценки эффективности	47
3.1.6 Ожидаемые результаты и ограничения апробации	49
3.2 Реализация методики на примере процесса обнаружения аномалий	50
3.2.1 Подготовительный этап пилотного проекта	51
3.2.2 Определение параметров анализа и настройка модели	52
3.2.3 Проведение пилотного проекта в режиме наблюдения	54
3.2.4 Анализ результатов и типология выявленных аномалий	54
3.2.5 Журнал аномалий пилотного проекта.....	57

3.2.6 Трудности, возникшие в ходе реализации пилотного проекта	58
3.2.7 Выводы по результатам реализации	59
3.3 Анализ результатов и оценка эффективности предложенных решений	60
3.3.1 Анализ полученных результатов	60
3.3.2 Сравнение с традиционными методами обнаружения	63
3.3.3 Оценка соответствия ожидаемым результатам	66
3.3.4 Обобщение результатов апробации	67
3.4 Выводы по третьей главе	69
ЗАКЛЮЧЕНИЕ	71
СПИСОК ЛИТЕРАТУРЫ	74
ПРИЛОЖЕНИЕ А	79
ПРИЛОЖЕНИЕ Б	83
ПРИЛОЖЕНИЕ В	93

ВВЕДЕНИЕ

Современный этап развития информационного общества характеризуется ростом числа инцидентов, связанных с нарушением конфиденциальности, целостности и доступности информации. Ежегодно фиксируется увеличение как количества кибератак [1], так и объемов утекающих баз данных, что создает существенные риски для организаций различных отраслей экономики. Актуальность темы исследования подтверждается статистикой инцидентов, связанных с компрометацией информации ограниченного доступа. По данным аналитического центра, специализирующегося на мониторинге утечек информации [2], за 2024 год зарегистрировано 778 фактов утечек информации ограниченного доступа. При этом количество скомпрометированных записей персональных данных превысило 1,5 млрд, что на 30% больше показателей предыдущего периода. В структуре инцидентов отмечается снижение доли кибератак при одновременном росте количества нарушений по вине внутреннего нарушителя, причем почти каждое пятое нарушение (около 20%) является следствием умышленных действий сотрудников. Данные тенденции свидетельствуют о недостаточной эффективности существующих систем защиты, ориентированных преимущественно на отражение внешних атак, и обосновывают необходимость внедрения технологий, ориентированных на выявление аномальной активности легитимных пользователей.

Параллельно с ростом внутренних угроз наблюдается усложнение внешних атак. Согласно данным экспертного центра в области кибербезопасности [3], по итогам 2025 года на Россию пришлось от 14% до 16% всех успешных кибератак в мире и 72% атак, зафиксированных в СНГ, при этом основными векторами проникновения остаются социальная инженерия и вредоносное программное обеспечение. Злоумышленники активно применяют полиморфное вредоносное программное обеспечение и

методы обхода сигнатурного анализа, что снижает эффективность традиционных средств защиты, функционирующих на основе детерминированных правил.

Таким образом, существующие системы управления информационной безопасностью (СУИБ), построенные преимущественно на сигнатурном методе и корреляционных правилах, не в полной мере обеспечивают обнаружение аномальной активности, особенно в случаях, когда действия нарушителя маскируются под легитимное поведение пользователя либо когда используется ранее неизвестное вредоносное программное обеспечение.

Потенциальным направлением решения данной проблемы выступает интеграция технологий искусственного интеллекта (ИИ), в частности методов машинного обучения и поведенческого анализа (User and Entity Behavior Analytics — UEBA), в процессы обнаружения угроз. Данные технологии позволяют перейти от поиска по известным шаблонам к вероятностному анализу отклонений от нормального поведения субъектов и объектов информационной системы. Однако анализ литературы и открытых кейсов показывает, что внедрение ИИ-решений в существующую СУИБ сопряжено с рядом организационных и технических трудностей: необходимостью подготовки качественных данных, нехваткой квалифицированных кадров, сложностью интерпретации результатов работы моделей. При этом формализованные методики такого внедрения, адаптированные для условий конкретного предприятия, проработаны недостаточно.

Следовательно, существует противоречие между потребностью в повышении эффективности обнаружения угроз и отсутствием апробированных методических рекомендаций по интеграции интеллектуальных технологий в контур СУИБ. Данное противоречие определяет актуальность настоящего исследования.

Объектом исследования выступает система управления информационной безопасностью общества с ограниченной ответственностью «Интегра-Софт» (ООО «Интегра-Софт»).

Предметом исследования являются методы, модели и организационно-технические процедуры интеграции технологий искусственного интеллекта в процессы обнаружения аномалий и инцидентов информационной безопасности.

Цель исследования заключается в повышении эффективности обнаружения компьютерных атак и нарушений политик безопасности за счет разработки и внедрения методических рекомендаций по интеграции технологий искусственного интеллекта в СУИБ ООО «Интегра-Софт».

Для достижения поставленной цели в работе решаются следующие задачи:

1. Провести анализ современных вызовов для СУИБ и оценить потенциал технологий ИИ для их решения.
2. Исследовать рынок решений и практические кейсы интеграции ИИ в ИБ для выявления типичных проблем и факторов успеха.
3. Разработать концептуальную модель и поэтапную методику интеграции ИИ в СУИБ.
4. Предложить подходы к организационно-кадровому обеспечению и оценке экономической эффективности внедрения.
5. Апробировать разработанную методику на примере процесса обнаружения аномалий и дать оценку её эффективности.

Теоретической основой исследования послужили научные труды и публикации в области управления информационной безопасностью, поведенческого анализа, машинного обучения, а также материалы профессиональных сообществ, нормативно-методические документы ФСТЭК России, Банка России, стандарты серии ГОСТ Р ИСО/МЭК 27000.

Методологическую основу составляют системный анализ, методы классификации, сравнительного анализа, экспериментального моделирования и экспертной оценки.

Практическая значимость исследования заключается в том, что разработанные методические рекомендации могут быть использованы руководителями подразделений информационной безопасности и ИТ-архитекторами для планирования и реализации проектов по внедрению систем поведенческого анализа и машинного обучения в корпоративную среду. Результаты апробации подтверждают возможность снижения времени обнаружения инцидентов и повышения качества работы аналитиков центра мониторинга безопасности.

Научная новизна работы состоит в систематизации разрозненных подходов к внедрению технологий искусственного интеллекта в системы управления информационной безопасностью и разработке комплексной методики, охватывающей полный цикл интеграции — от стратегического планирования и выбора пилотного процесса до оценки экономической эффективности в условиях промышленной эксплуатации. В отличие от существующих решений, ориентированных преимущественно на технические аспекты внедрения, предложенная методика учитывает организационно-кадровые аспекты, включая управление изменениями и требования к компетенциям персонала центров мониторинга безопасности (SOC).

Работа состоит из введения, трех глав, заключения, списка литературы и двух приложений. Первая глава посвящена теоретическим основам и анализу современных вызовов для СУИБ. Во второй главе разрабатываются методические рекомендации по интеграции ИИ в СУИБ. В третьей главе представлены результаты апробации предложенной методики на примере ООО «Интегра-Софт». Список литературы включает 48 наименований.

ГЛАВА 1. ТЕОРЕТИКО-АНАЛИТИЧЕСКИЕ ОСНОВЫ ИНТЕГРАЦИИ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА В СИСТЕМУ УПРАВЛЕНИЯ ИНФОРМАЦИОННОЙ БЕЗОПАСНОСТЬЮ

1.1 Современные вызовы для систем управления информационной безопасностью и ограничения традиционных систем защиты

Система управления информационной безопасностью (СУИБ) современного предприятия представляет собой комплекс организационных и технических мер, направленных на обеспечение конфиденциальности, целостности и доступности информации. Традиционно основу технической части СУИБ составляли средства сигнатурного анализа, межсетевые экраны и системы сбора и корреляции событий (SIEM), функционирующие на основе детерминированных правил. Однако эволюция ландшафта угроз выявляет системные ограничения данных подходов. Регуляторные требования к разработке и сертификации программного обеспечения постоянно ужесточаются: например, новый ГОСТ Р 56939–2024, учитывающий требования ФСТЭК, вводит 25 обязательных процессов безопасной разработки, что повышает нагрузку на организации-разработчики и требует интеграции новых подходов к защите [3].

- Проблема обнаружения неизвестных угроз.

Сигнатурный метод, лежащий в основе работы большинства антивирусных средств и систем обнаружения вторжений (IDS), эффективен лишь против уже известного вредоносного программного обеспечения. Для выявления новых или модифицированных угроз, включая полиморфное вредоносное ПО и атаки, эксплуатирующие уязвимости нулевого дня (zero-day), данный метод не применим, так как требует наличия актуальной сигнатуры в базе. Временной промежуток между появлением новой угрозы и выпуском сигнатуры (так называемое «окно уязвимости») может составлять от

нескольких часов до нескольких суток, что создает критический риск для организации. Масштаб угрозы подтверждается статистикой: только в первом полугодии 2025 года количество кибератак на российские организации превысило 63 тысячи, что на 27 % больше, чем за аналогичный период 2024 года [4].

- Высокая нагрузка на аналитиков и ложные срабатывания.

SIEM-системы, агрегирующие события от множества источников, генерируют значительный поток предупреждений. Значительная часть этих предупреждений является ложными срабатываниями (false positive). Сотрудники центров мониторинга безопасности (SOC) вынуждены вручную разбирать тысячи событий ежедневно, что приводит к снижению концентрации внимания и повышению вероятности пропуска действительно критического инцидента. Кроме того, поддержание корреляционных правил в актуальном состоянии требует постоянных трудозатрат, особенно в условиях динамически изменяющейся ИТ-инфраструктуры.

- Сложность выявления внутренних нарушителей.

Действия инсайдера, обладающего легитимным доступом к информации, крайне сложно идентифицировать с помощью традиционных правил. Если злоумышленник использует штатные средства и действует в рамках своих полномочий, его активность может не отличаться от обычной работы пользователя. Обнаружение такого рода угроз требует не анализа отдельных событий, а построения долгосрочной модели поведения и выявления отклонений от нее, что не входит в функционал классических SIEM.

Показательным примером является инцидент с бывшим сотрудником Google, который, обладая избыточными привилегиями, скачал более 2000 документов с секретами ИИ-разработок, и его действия оставались незамеченными из-за отсутствия эффективного контроля и мониторинга [5]. Данный случай демонстрирует, что даже в технологически развитых

компаниях проблема выявления внутренних нарушителей остается острой и требует применения более совершенных методов анализа поведения.

- Ограниченная применимость в условиях зашифрованного трафика.

Растущая доля сетевого трафика передается с использованием зашифрованных протоколов (HTTPS, TLS). Традиционные средства анализа сети (NGFW, IDS) теряют возможность инспектировать содержимое пакетов, что снижает их эффективность. Решение данной проблемы требует либо повсеместного внедрения систем расшифровки трафика, либо перехода к анализу метаданных и поведенческих характеристик сетевых соединений. Современные подходы позволяют анализировать зашифрованный трафик без его расшифровки, используя такие параметры, как размер пакетов, частотность обращений и временные характеристики соединений, что помогает выявлять аномалии и атаки, невидимые для традиционных систем [6].

- Кадровый дефицит и высокая стоимость эксплуатации.

Эффективная работа традиционных SIEM-систем требует участия высококвалифицированных экспертов по безопасности, способных писать сложные корреляционные правила и разбирать инциденты. Рынок таких специалистов характеризуется острым дефицитом, а затраты на содержание большой аналитической группы могут быть непосильными для организаций среднего бизнеса. Как показывают опросы, именно нехватка кадров и экспертизы (69 %) и недостаток бюджета (61 %) являются основными препятствиями для выполнения современных требований по безопасности, особенно в отношении объектов критической информационной инфраструктуры [7].

Таким образом, совокупность перечисленных факторов — неспособность обнаруживать неизвестные угрозы, высокий уровень ложных срабатываний, сложность выявления инсайдеров и кадровый дефицит — свидетельствует о том, что традиционные методы защиты достигли предела

своей эффективности. Дальнейшее развитие СУИБ требует перехода к качественно иным подходам, основанным на анализе поведения и выявлении аномалий. В качестве одного из таких подходов рассматриваются технологии ИИ, анализ которых представлен в следующем параграфе.

1.2 Технологии искусственного интеллекта и анализ их применимости для задач информационной безопасности

Рост объема данных, подлежащих анализу, и усложнение методов атак обусловили необходимость поиска новых подходов к обнаружению угроз. Технологии искусственного интеллекта (ИИ), и в частности машинного обучения, позволяют автоматизировать выявление скрытых закономерностей и аномалий, что делает их востребованным инструментом в арсенале средств защиты информации. В данном параграфе рассматриваются основные классы таких технологий и оценивается их применимость для решения задач информационной безопасности.

1.2.1 Машинное обучение (Machine Learning)

Машинное обучение представляет собой совокупность методов, позволяющих системе выявлять закономерности в данных без явного программирования правил. Как отмечается в современных исследованиях, применение методов машинного обучения в сфере кибербезопасности позволяет автоматизировать процессы обнаружения атак и снизить нагрузку на аналитиков [8]. В контексте инф можно выделить два основных подхода.

- Обучение с учителем (Supervised Learning).

Данный подход предполагает наличие размеченного набора данных, в котором каждому объекту (например, файлу или сетевому соединению)

заранее присвоен признак класса: «вредоносный» или «легитимный». Модель обучается на этой разметке и в дальнейшем пытается классифицировать новые объекты. Этот метод эффективен для задач, где накоплено достаточное количество исторических данных: обнаружение спама, фильтрация веб-трафика, сигнатурный анализ нового поколения (с использованием эвристик). Однако ограничением данного подхода является зависимость от качества и полноты обучающей выборки, а также неспособность выявлять принципиально новые типы атак, отсутствовавшие в обучающих данных.

- Обучение без учителя (Unsupervised Learning).

В отличие от предыдущего подхода, обучение без учителя не требует размеченных данных. Модель самостоятельно ищет структуру во входном потоке, группируя схожие объекты и выявляя объекты, которые выбиваются из общего ряда (аномалии). Именно этот подход наиболее интересен для задач обнаружения неизвестных угроз и действий внутренних нарушителей. Алгоритмы данного класса позволяют строить профили нормального поведения пользователей и устройств и реагировать на отклонения от этих профилей.

1.2.2 Поведенческий анализ (UEBA)

User and Entity Behavior Analytics (UEBA) — это класс решений, основанных на применении машинного обучения (преимущественно обучения без учителя) для анализа поведения субъектов (пользователей) и объектов (серверов, приложений, устройств) информационной системы. Технология UEBA позволяет решать следующие задачи:

- выявление скомпрометированных учетных записей (когда злоумышленник действует от имени легитимного пользователя);
- обнаружение инсайдерской активности (несанкционированный доступ к данным, их копирование);

- выявление аномалий в работе сервисов и приложений.

Ключевое преимущество UEBA заключается в том, что система не ищет конкретные «плохие» действия, а обнаруживает любое поведение, отклоняющееся от типичного для данного субъекта или объекта. Это позволяет выявлять атаки, не имеющие известных сигнатур.

1.2.3 Обработка естественного языка (NLP)

Технологии обработки естественного языка (Natural Language Processing, NLP) находят применение в информационной безопасности преимущественно в двух областях:

- анализ текстовых каналов коммуникаций (электронная почта, мессенджеры) для предотвращения утечек конфиденциальной информации и выявления признаков мошенничества;
- автоматизированная обработка отчетов об угрозах (Threat Intelligence Feeds) — извлечение из неструктурированных текстов (статей, блогов, отчетов) информации о новых уязвимостях, тактиках злоумышленников и индикаторах компрометации.

Подобные данные, называемые также индикаторами компрометации (IoC) и индикаторами атаки (IoA), позволяют перейти от реактивной модели защиты к проактивной и являются основой для работы специализированных платформ киберразведки [9].

1.2.4 Сводный анализ применимости технологий

Для наглядности соотношение технологий искусственного интеллекта и задач информационной безопасности представлено в таблице 1.1.

Таблица 1.1 — Применимость технологий ИИ для задач ИБ

Технология	Класс методов	Основные задачи ИБ
Машинное обучение (с учителем)	Классификация	Антивирусная защита нового поколения, фильтрация спама и веб-трафика, предиктивная аналитика инцидентов
Машинное обучение (без учителя)	Кластеризация, обнаружение аномалий	Поиск неизвестных угроз, выявление аномальной активности пользователей и устройств
Поведенческий анализ (UEBA)	Комплекс методов машинного обучения	Обнаружение скомпрометированных учетных записей, инсайдерских действий, аномалий в поведении сервисов
Обработка естественного языка (NLP)	Анализ текста	DLP-системы (анализ переписок), автоматическая обработка данных киберразведки

Таким образом, каждая из рассмотренных технологий имеет свою область применения. Для решения задач, поставленных в данном исследовании, наибольший потенциал представляют методы машинного обучения без учителя и поведенческий анализ (UEBA). Именно эти технологии будут положены в основу разрабатываемой в Главе 2 методики интеграции ИИ в СУИБ.

1.3 Анализ рынка решений и кейсов интеграции искусственного интеллекта в информационную безопасность

Интеграция технологий искусственного интеллекта в продукты и процессы информационной безопасности является одним из основных трендов развития отрасли. В прогнозах ведущих экспертов на 2026 год эта тема занимает первую строчку по частотности упоминаний, являясь «безусловным лидером» как в части анализа угроз, так и в части развития средств защиты [10]. Согласно данным аналитических обзоров, 22% специалистов назвали

машинное обучение и искусственный интеллект главным локомотивом развития ИТ в 2025 году, а кибербезопасность выделена как одно из ключевых направлений роста [11]. На рынке представлено множество решений — от крупных платформ, включающих ИИ-модули, до узкоспециализированных стартапов. Однако анализ реальных кейсов внедрения показывает, что наличие технологии само по себе не гарантирует результата. В данном параграфе рассматривается структура рынка, а также обобщаются типичные проблемы и факторы успеха проектов по интеграции ИИ в СУИБ.

1.3.1 Обзор рынка решений

Рынок ИИ-решений для ИБ условно можно разделить на несколько категорий.

- Крупные вендоры с интегрированными ИИ-платформами.

Ведущие производители средств защиты информации активно встраивают модули машинного обучения и поведенческого анализа в свои продукты. К данной категории относятся как международные компании (например, Microsoft), так и российские разработчики: «Лаборатория Касперского», Positive Technologies, «ИнфоВотч», Solar Security. Преимуществом таких решений является их комплексность и наличие встроенных экспертных знаний вендора. Недостатком — высокая стоимость и зависимость от конкретного производителя.

Важно отметить, что эффективная защита строится не на отдельном продукте, а на их согласованном взаимодействии. Современные исследования предлагают архитектуры СУИБ, объединяющие средства обнаружения угроз на конечных точках, контроля потоков данных, сетевой безопасности и оркестрации реагирования, что позволяет автоматизировать процессы противодействия кибератакам на всех этапах — от обнаружения до восстановления [12]. Такой подход подтверждает, что интеграция различных

средств в рамках единой методологической основы является ключевым фактором построения эффективной системы защиты.

- Специализированные платформы поведенческого анализа.

Ряд компаний фокусируется исключительно на поведенческом анализе. Такие решения глубже прорабатывают математические модели, но требуют отдельной интеграции с существующей инфраструктурой (SIEM, источники событий). На российском рынке присутствуют как собственные разработки, так и адаптированные решения, однако в условиях импортозамещения доля отечественных продуктов в этом сегменте растет.

- Решения с открытым исходным кодом (open-source).

Для организаций с сильной командой разработки и аналитики данных доступны инструменты с открытым исходным кодом, позволяющие создавать собственные модели машинного обучения. Такой подход дает возможность гибкой настройки и полного контроля над процессом. Однако он требует высокой квалификации персонала и значительных временных затрат. Кроме того, использование open-source компонентов сопряжено с дополнительными рисками: по статистике, 79 % сторонних библиотек не обновляются, что создает устойчивую уязвимость для атак на цепочки поставок через репозитории кода [13].

1.3.2 Типичные проблемы и риски внедрения

Анализ открытых источников и отраслевых публикаций позволяет выделить несколько системных проблем, с которыми сталкиваются организации при интеграции ИИ в ИБ.

- Проблема качества данных.

Модели машинного обучения требуют больших объемов релевантных, полных и очищенных данных для обучения. Если в организации не налажен

процесс сбора и нормализации событий безопасности, эффективность внедрения ИИ-решений существенно снижается. Многие компании в погоне за быстрым результатом игнорируют фундаментальный аспект – анализ качества данных, на которых будут обучаться или дообучаться модели. В итоге системы, на которые возлагались большие надежды, начинают выдавать ошибочные или предвзятые результаты, подрывая доверие к технологии [14].

- Проблема интерпретируемости («черный ящик»).

Сложность объяснения результатов работы нейросетевых моделей снижает доверие к ним со стороны аналитиков. В отличие от классического корреляционного правила, решение ИИ-модели часто неочевидно. Аналитик, не понимающий, почему система выдала предупреждение, склонен его игнорировать. Эта проблема осознается и на уровне регуляторов: ключевым требованием к надежным системам искусственного интеллекта становится их прозрачность и способность объяснять принятые решения, что отражено в международных и национальных стандартах [15].

- Дефицит специалистов с компетенциями в области ИИ.

Эффективная эксплуатация систем искусственного интеллекта в сфере информационной безопасности требует специалистов, обладающих одновременно компетенциями в двух областях: понимания принципов работы средств защиты информации (SIEM, DLP, антивирусы) и владения методами анализа данных, машинного обучения. Дефицит таких специалистов является системной проблемой отрасли: по данным исследований, 41 % компаний по всему миру испытывают нехватку экспертов по информационной безопасности, причем 35 % из этого числа приходится на аналитиков центров мониторинга безопасности (SOC) [16]. Организации вынуждены либо доучивать сотрудников служб безопасности, либо привлекать аналитиков данных и погружать их в специфику ИБ, что требует времени и ресурсов. Дефицит кадров приводит к тому, что даже приобретенные ИИ-решения могут

использоваться неэффективно или простаивать из-за отсутствия персонала, способного с ними работать.

- Высокий уровень ложных срабатываний на начальном этапе.

При первом запуске ИИ-модули, особенно построенные на обучении без учителя, могут генерировать большое количество аномалий, многие из которых являются ложными. Это создает дополнительную нагрузку на аналитиков и может вызвать отторжение технологии. В среднем по отрасли 63,8 % специалистов SOC называют ложные срабатывания главной проблемой, а 57 % центров мониторинга вынуждены подавлять шумные правила, из-за чего около 40 % предупреждений остаются непроанализированными [17].

- Устаревание моделей со временем.

Модели машинного обучения, однажды обученные, со временем перестают соответствовать реальной ситуации. Инфраструктура меняется, появляются новые сотрудники, приложения, меняются бизнес-процессы. Без регулярного обновления и обратной связи от аналитиков точность модели снижается. Ситуация усугубляется использованием в инфраструктуре программного обеспечения, которое утратило возможность получения обновлений и патчей безопасности. Такое ПО создает дополнительные уязвимости и требует постоянной адаптации моделей для корректного обнаружения аномалий в изменившейся среде [18].

- Регуляторные риски и «регуляторный долг».

Отдельную группу рисков составляют регуляторные требования, невыполнение которых может привести к значительным финансовым и административным санкциям. В российских условиях 2026–2027 годов компании сталкиваются с феноменом «регуляторного долга» — накопления невыполненных или формально выполненных обязательств перед регуляторами (ФСТЭК, Роскомнадзор, ЦБ) по законам 152-ФЗ, 187-ФЗ и подзаконным актам. Дефицит кадров (прогнозируемая нехватка до 60 000

специалистов к 2027 году) и рост стоимости сертифицированного ПО (на 10–40 %) вынуждают бизнес выбирать между формальным соответствием и реальным укреплением безопасности, что усугубляет уязвимость инфраструктуры [19].

- Новые риски, связанные с внедрением ИИ-агентов.

Развитие технологий приводит к появлению принципиально новых субъектов в контуре информационной безопасности — автономных ИИ-агентов, которые действуют от имени служебных учетных записей и имеют доступ к изменению конфигураций систем, коду и данным. Формируется новый класс нечеловеческих идентичностей (Non-Human Identity), поведение которых сложно прогнозировать и контролировать традиционными методами. Актуальность данной угрозы подтверждается статистикой: по данным исследований, до 40 % внутренних инцидентов безопасности уже прямо или косвенно связаны с автономными ИИ-агентами, а 76 % руководителей по информационной безопасности в крупных организациях отмечают, что ИИ-агенты стали самой сложной для контроля категорией [20]. Согласно данным отраслевых исследований, до 25 % организаций уже сталкивались с утечками данных, в которых были задействованы такие агенты, а около 80 % фиксировали попытки несанкционированного доступа, связанные с их использованием. Основной вектор атак смещается в сторону перехвата управления агентом, когда злоумышленники пытаются подменить внутренние инструкции системы, чтобы использовать ее легитимные права в деструктивных целях. Более 60 % атак на автономные системы направлены именно на это. Данный класс рисков требует разработки дополнительных мер контроля, включая семантическую проверку действий агентов и мониторинг целостности их контекста [21].

1.3.3 Анализ успешных практик

Несмотря на перечисленные сложности, существует множество примеров успешной интеграции искусственного интеллекта в процессы информационной безопасности. Обобщение опыта компаний, которым удалось добиться результата, позволяет выделить несколько общих факторов, определяющих успех внедрения.

1. Поэтапный подход и выбор пилотного проекта.

Успешные внедрения редко начинаются с попытки охватить сразу все процессы мониторинга. Как правило, компании выбирают одну критичную, но ограниченную задачу, где эффект от применения искусственного интеллекта можно быстро измерить и продемонстрировать. Наиболее часто в качестве такого пилотного проекта выбирается мониторинг действий привилегированных пользователей или анализ почтового трафика на предмет фишинга. Выбор этих направлений не случаен: они позволяют противодействовать таким актуальным угрозам, как атаки через подрядчиков и использование шифровальщиков, с которыми, по данным экспертов, в 2025 году столкнулись 6 % крупных российских компаний [22]. Успех на ограниченном участке создает основу для масштабирования решения на другие процессы.

2. Высокое качество данных на входе.

Ключевым условием успешной работы моделей машинного обучения является качество данных, на которых они обучаются и функционируют. В проектах, признанных успешными, перед внедрением ИИ-модулей проводится аудит источников событий, налаживается централизованный сбор и нормализация логов. Инвестиции в «культуру данных» окупаются точностью работы моделей и низким уровнем ложных срабатываний.

3. Наличие обратной связи от аналитиков.

Модели машинного обучения, особенно построенные на принципах обучения без учителя, не являются статичными. Для поддержания их актуальности необходим контур обратной связи: аналитик, разбирая инцидент, должен иметь возможность подтвердить или опровергнуть вывод системы. Полученные данные используются для дообучения модели, что повышает ее точность и позволяет адаптироваться к изменениям в инфраструктуре и тактиках злоумышленников.

4. Интеграция в существующие процессы, а не их замена.

Наиболее эффективной стратегией является не замена существующих средств защиты на ИИ-решения, а их встраивание в уже работающий контур центра мониторинга безопасности (SOC). ИИ-модули выступают в роли ассистента аналитика, помогая фильтровать поток ложных срабатываний, подсвечивать аномалии и обогащать данные контекстом. Такой подход позволяет использовать сильные стороны как человека, так и машины. Практика показывает, что грамотное применение ИИ способно дать измеримый результат: в ряде организаций внедрение интеллектуальных ассистентов позволило снизить трудозатраты аналитиков первой линии (осуществляющих первичный разбор событий) примерно на 30 % [23]. При этом ключевая роль в принятии окончательного решения об инциденте должна оставаться за человеком, а искусственный интеллект выступает в роли инструмента, ускоряющего обработку событий.

Обобщение выявленных проблем и факторов успеха, а также их значение для разработки практических рекомендаций представлено в выводах по первой главе (п. 1.4).

1.4 Выводы по первой главе

Проведенное в первой главе исследование позволяет сформулировать следующие основные выводы.

1. Традиционные системы защиты не обеспечивают должного обнаружения современных угроз. Ключевые ограничения: неспособность выявлять неизвестные атаки и действия инсайдеров, высокий уровень ложных срабатываний, неэффективность при анализе зашифрованного трафика, высокие требования к персоналу.
2. Технологии искусственного интеллекта, особенно методы обучения без учителя и поведенческий анализ (UEBA), позволяют преодолеть эти ограничения за счет выявления аномалий вместо поиска по известным шаблонам.
3. Анализ рынка и практических кейсов показывает, что успех внедрения искусственного интеллекта определяется преимущественно организационными факторами. Ключевыми проблемами являются качество исходных данных, дефицит кадров, сложность интерпретации результатов работы моделей и их устаревание. Успешные проекты, в свою очередь, характеризуются поэтапным подходом, обеспечением качества данных, наличием обратной связи от аналитиков и встраиванием искусственного интеллекта в существующие процессы в роли ассистента.

Таким образом, результаты анализа, проведенного в первой главе, подтверждают актуальность темы исследования и обосновывают необходимость разработки методических рекомендаций по интеграции технологий искусственного интеллекта в систему управления информационной безопасностью, учитывающих выявленные проблемы и лучшие практики. Разработке такой методики посвящена вторая глава настоящей работы.

ГЛАВА 2. РАЗРАБОТКА МЕТОДИЧЕСКИХ РЕКОМЕНДАЦИЙ ПО ИНТЕГРАЦИИ ТЕХНОЛОГИЙ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА В СИСТЕМУ УПРАВЛЕНИЯ ИНФОРМАЦИОННОЙ БЕЗОПАСНОСТЬЮ

2.1 Концептуальная модель и этапы интеграции искусственного интеллекта в процессы системы управления информационной безопасностью

Результаты анализа, проведенного в первой главе, показали, что существующие системы управления информационной безопасностью, построенные на детерминированных правилах, не в полной мере справляются с современными угрозами. Технологии искусственного интеллекта обладают потенциалом для преодоления этих ограничений, однако их внедрение требует системного подхода. Бессистемная интеграция ИИ-решений, без учета архитектурных и организационных аспектов, приводит к низкой эффективности и отторжению технологий. В связи с этим возникает необходимость разработки концептуальной модели, определяющей место ИИ в контуре СУИБ, и формализации этапов его внедрения.

Предлагаемая концептуальная модель исходит из того, что ИИ не заменяет существующие средства защиты, а дополняет их, работая в связке с традиционными инструментами и человеком. Общая логика функционирования модели выглядит следующим образом.

На вход системы поступает поток данных из различных источников: событий от средств защиты (антивирусы, межсетевые экраны), логов операционных систем и приложений, сетевого трафика, данных о действиях пользователей. Этот поток параллельно обрабатывается двумя контурами:

- Традиционный детерминированный контур, включающий SIEM-систему с корреляционными правилами и сигнатурные анализаторы. Он отвечает за выявление известных угроз по заданным шаблонам.
- Интеллектуальный контур, включающий модули на базе машинного обучения и поведенческого анализа (UEBA). Его задача — выявление аномалий, неизвестных угроз и скрытых закономерностей.

Результаты работы обоих контуров поступают аналитику центра мониторинга безопасности (SOC). При этом ИИ-модуль выступает в роли ассистента, который не генерирует окончательные решения, а подсвечивает подозрительную активность, предоставляет дополнительный контекст и ранжирует события по степени критичности. Окончательное решение об отнесении события к категории инцидента и выборе мер реагирования остается за человеком. Такой подход, известный как «человек в контуре» (Human-in-the-loop), позволяет сочетать вычислительные мощности алгоритмов с опытом и интуицией эксперта, а также постепенно накапливать данные для дообучения моделей.

Реализация данной модели требует прохождения ряда последовательных этапов, которые в обобщенном виде можно представить следующим образом:

1. Подготовительный этап (диагностика). На данном этапе проводится аудит существующей инфраструктуры сбора событий, оценивается качество и полнота данных, выбирается пилотный процесс для первоначального внедрения.
2. Этап пилотного проекта. Осуществляется развертывание ИИ-модуля в режиме наблюдения, когда система получает данные, но не влияет на процессы. Производится оценка точности модели, уровня ложных срабатываний, собирается обратная связь от аналитиков.
3. Этап промышленного внедрения. Производится интеграция ИИ-модуля в операционные процессы SOC, предупреждения от системы начинают

поступать в общую очередь инцидентов, настраиваются сценарии реагирования.

4. Этап эксплуатации и развития. Обеспечивается регулярное дообучение моделей на основе накопленных данных, мониторинг эффективности, адаптация к изменениям в инфраструктуре.

Детальная проработка каждого из перечисленных этапов, включая конкретные шаги, критерии принятия решений и организационное обеспечение, представлена в следующем параграфе.

2.2 Поэтапная методика интеграции технологий искусственного интеллекта в систему управления информационной безопасностью

В предыдущем параграфе были определены ключевые этапы интеграции технологий искусственного интеллекта в контур СУИБ. Настоящий параграф посвящен детальному описанию каждого из этих этапов, включая конкретные действия, критерии принятия решений и ожидаемые результаты. Потребность в формализации такого подхода подтверждается практикой рынка: компании переходят от вопроса «нужно ли внедрять ИИ?» к вопросам «как быстро масштабировать пилотные решения?» и «как оценить их реальную эффективность?» [24]. Предлагаемая методика носит универсальный характер и может быть адаптирована под условия конкретного предприятия с учетом масштаба его инфраструктуры и доступных ресурсов.

Обобщенная последовательность этапов интеграции искусственного интеллекта в систему управления информационной безопасности представлена на рисунке 2.1. Схема иллюстрирует логику перехода между четырьмя ключевыми этапами: от первоначальной диагностики и выбора пилотного процесса до промышленной эксплуатации и дальнейшего развития системы.

Рисунок 2.1 — Этапы интеграции технологий ИИ в СУИБ



Этап 1. Подготовка и диагностика.

Целью данного этапа является оценка готовности инфраструктуры к внедрению ИИ и выбор направления для пилотного проекта. Успех всего внедрения напрямую зависит от качества подготовки на этом этапе.

В рамках подготовительного этапа выполняются следующие работы:

- Аудит источников данных. Проводится инвентаризация всех источников событий информационной безопасности: серверов, рабочих станций,

сетевого оборудования, средств защиты (SIEM, DLP, межсетевые экраны). Оценивается полнота и непротиворечивость передаваемых данных, наличие критически важных событий (например, логи входа/выхода, запуска процессов, доступа к файлам).

- Оценка качества данных. Анализируются логи за репрезентативный период (например, 1–3 месяца) на предмет пропусков, дубликатов, некорректных форматов. Выявляются источники с низкой информативностью, генерирующие избыточное количество незначимых событий. Результатом анализа должно стать понимание, какие данные пригодны для обучения моделей, а какие требуют очистки или донастройки. Особое внимание следует уделять происхождению данных и их защите от возможной компрометации, поскольку отравление обучающих наборов является одной из ключевых угроз для ИИ-систем [25].
- Выбор пилотного процесса. На основе анализа текущих проблем и наиболее критичных зон существующей системы защиты выбирается один, реже два процесса для первоначального внедрения ИИ. Критериями выбора служат: высокая значимость процесса для организации, наличие достаточного объема данных для обучения, возможность быстрой оценки результатов. Наиболее часто в качестве пилотных выбираются следующие процессы:
 - обнаружение аномалий в действиях привилегированных пользователей;
 - выявление подозрительной активности на рабочих станциях;
 - анализ почтового трафика на предмет фишинговых рассылок.
- Формирование требований. Определяются функциональные и нефункциональные требования к ИИ-модулю: какие именно аномалии он должен выявлять, с какой точностью, как часто, в каком виде предоставлять результаты, как интегрироваться с существующей SIEM-системой и системой учета инцидентов.

Этап 2. Пилотный проект.

На данном этапе производится развертывание выбранного ИИ-решения (коммерческого продукта или собственной разработки) в режиме ограниченного функционала. Ключевой принцип пилота — отсутствие влияния на операционные процессы. Система работает в режиме наблюдения, получая данные, но не генерируя предупреждения, которые могли бы отвлечь аналитиков или повлиять на ход расследования инцидентов.

Этап пилотного проекта включает следующие шаги:

- Развертывание и настройка. Устанавливается и конфигурируется ИИ-модуль, налаживается получение данных из выбранных источников.
- Обучение модели. На исторических данных (за период, определенный на этапе 1) производится обучение модели. Для методов обучения без учителя этот процесс заключается в построении базовой линии «нормального» поведения пользователей и систем.
- Оценка результатов. В течение 1–2 месяцев работы в режиме наблюдения собирается статистика:
 - количество выявленных аномалий;
 - доля подтвержденных инцидентов (по оценке аналитиков);
 - доля ложных срабатываний;
 - время обнаружения по сравнению с традиционными методами.
- Сбор обратной связи. Аналитики, участвующие в пилоте, фиксируют свои впечатления от работы с системой: насколько понятны ее выводы, удобен ли интерфейс, помогает ли она в работе или создает дополнительную нагрузку. Эксперты подчеркивают, что для успешного внедрения SIEM нового поколения критически важен баланс между мощными возможностями и простотой использования, чтобы работа с системой не требовала значительных ресурсов и усилий [26].

По итогам пилотного проекта принимается одно из следующих решений:

- переход к промышленному внедрению (при удовлетворительных результатах);
- доработка модели и повторный пилот (при высоком уровне ложных срабатываний);
- отказ от внедрения (если результаты признаны неудовлетворительными, а доработка невозможна или нецелесообразна).

Этап 3. Промышленное внедрение.

После успешного завершения пилотного проекта ИИ-модуль встраивается в регулярные процессы центра мониторинга безопасности.

Основные работы на этом этапе:

- Интеграция в процессы SOC. Предупреждения от ИИ-системы начинают поступать в общую очередь инцидентов (например, в систему учета инцидентов или платформу автоматизации реагирования). Для них назначаются приоритеты и правила эскалации.
- Обучение персонала. Проводится обучение аналитиков работе с новым инструментом: объясняется логика его работы, правила интерпретации выводов, порядок действий при получении предупреждений.
- Настройка сценариев реагирования. Определяется, какие действия должны выполняться автоматически (например, изоляция узла при подтверждении инцидента), а какие — только по решению человека.
- Документирование. Разрабатываются или обновляются регламенты работы SOC, включающие описание процессов с использованием ИИ-модуля. При разработке регламентов целесообразно руководствоваться требованиями ГОСТ Р ИСО/МЭК 27001–2021 в части управления инцидентами информационной безопасности [27].

Этап 4. Эксплуатация и развитие.

Внедрение ИИ не является разовым мероприятием. Для поддержания эффективности системы необходимо обеспечить ее постоянное развитие и адаптацию к изменяющимся условиям.

Ключевые активности на этапе эксплуатации:

- Регулярное дообучение моделей. Накопленные данные о подтвержденных инцидентах и ложных срабатываниях используются для периодического (например, ежеквартального) дообучения моделей, что повышает их точность.
- Мониторинг эффективности. Ведется постоянный контроль ключевых показателей (например, доля ложных срабатываний, среднее время обнаружения, количество инцидентов, выявленных только с помощью ИИ).
- Адаптация к изменениям. При существенных изменениях в ИТ-инфраструктуре (внедрение новых систем, реорганизация) проводится анализ их влияния на работу ИИ-модулей и, при необходимости, корректировка моделей.
- Масштабирование. После успешной эксплуатации на пилотном процессе опыт внедрения распространяется на другие направления мониторинга безопасности.

Предложенная поэтапная методика позволяет минимизировать риски, связанные с внедрением технологий искусственного интеллекта, и обеспечить их органичное встраивание в существующие процессы управления информационной безопасностью. Вопросы организационно-кадрового обеспечения и оценки экономической эффективности, являющиеся неотъемлемой частью предлагаемого подхода, рассматриваются в следующем параграфе.

2.3 Организационно-кадровое обеспечение внедрения и методы оценки экономической эффективности

Разработанная в предыдущих параграфах поэтапная методика интеграции технологий искусственного интеллекта в СУИБ определяет последовательность технических и организационных шагов. Однако успех внедрения невозможен без учета двух ключевых аспектов: готовности персонала работать с новыми инструментами и возможности оценить реальную выгоду от внедрения. Настоящий параграф посвящен вопросам кадрового обеспечения проекта и методам оценки его экономической эффективности.

2.3.1 Организационно-кадровое обеспечение

Внедрение ИИ-модулей в процессы мониторинга безопасности предъявляет новые требования к компетенциям сотрудников центра мониторинга безопасности (SOC). При этом речь не всегда идет о необходимости найма новых специалистов; во многих случаях достаточно развития навыков существующей команды.

1. Изменение ролей и функций.

Внедрение ИИ приводит к перераспределению задач между аналитиками. При этом важно понимать, что эффективное расследование инцидентов, особенно связанных с внутренними нарушениями, требует взаимодействия служб информационной и экономической безопасности. По различным оценкам, доля внутренних нарушителей может достигать 75 % от всех инцидентов, а в российских компаниях эта цифра приближается к 95 %, если учитывать случаи, когда внешние злоумышленники действуют через сообщников внутри организации [28].

- Аналитики первой линии, ранее занимавшиеся преимущественно ручной сортировкой событий, получают возможность сосредоточиться на более сложных задачах, так как часть рутинной работы автоматизируется.
- Аналитики второй и третьей линий должны быть готовы к взаимодействию с ИИ-ассистентом: интерпретировать его выводы, проверять обоснованность предупреждений, передавать системе обратную связь для дообучения.
- В команде может появиться специалист (или выделенная функция), отвечающий за мониторинг качества работы моделей, их периодическое дообучение и адаптацию к изменениям инфраструктуры. Эту роль способен выполнять наиболее квалифицированный аналитик, прошедший дополнительное обучение.

2. Требования к компетенциям.

Для эффективной работы в новых условиях сотрудники SOC должны обладать следующими знаниями и навыками:

- понимание принципов работы методов машинного обучения, их сильных сторон и ограничений;
- умение интерпретировать результаты работы моделей, отличать значимые аномалии от прочих отклонений;
- навыки работы с интерфейсами ИИ-модулей и системами визуализации данных;
- понимание важности обратной связи для дообучения моделей и готовность ее предоставлять.

3. Обучение и развитие персонала.

Обеспечение необходимых компетенций требует организации системы обучения, которая может включать:

- вводный тренинг для всех аналитиков SOC по основам работы с ИИ-модулем;
- специализированные курсы для сотрудников, отвечающих за дообучение моделей (возможно, с привлечением вендора решения);
- регулярный обмен опытом внутри команды, разбор сложных кейсов, выработка лучших практик взаимодействия с системой.

Следует также учитывать, что в современных российских условиях требования к компетенциям и ответственности руководителей ИТ и ИБ существенно возрастают. Согласно данным надзорных органов, в 2026 году размер штрафов для должностных лиц за нарушения в сфере защиты информации может достигать 1,5 млн рублей, а ответственность за инциденты становится персональной [29]. Это требует от руководителей не только глубокого понимания технических аспектов внедряемых решений, но и умения формализовать запросы на финансирование мер защиты, документировать принимаемые решения и выстраивать систему контроля, способную противостоять растущим регуляторным рискам.

Кроме того, при планировании штатной численности и компетенций команды необходимо учитывать реалии рынка труда. Как показывают отраслевые исследования, средний срок найма квалифицированного аналитика для SOC может составлять от 2 до 6 месяцев, при этом для укомплектования только первой линии требуется не менее 5 специалистов [30]. Данный фактор должен быть учтен при разработке дорожных карт внедрения ИИ-решений, чтобы избежать ситуации, когда приобретенные технологии простаивают из-за отсутствия персонала, способного с ними работать.

2.3.2 Методы оценки экономической эффективности

Оценка эффективности внедрения искусственного интеллекта в информационную безопасность имеет свою специфику, поскольку прямую

прибыль такие проекты, как правило, не приносят. Их цель — предотвращение ущерба и повышение эффективности работы подразделения. Тем не менее, существуют подходы, позволяющие оценить выгоду от внедрения в числовом выражении.

1. Затраты на внедрение и эксплуатацию.

Для расчета полной стоимости владения необходимо учесть следующие категории затрат:

- прямые затраты: стоимость лицензий на программное обеспечение или подписки, затраты на приобретение или аренду дополнительного оборудования (серверы, системы хранения данных);
- затраты на внедрение: оплата услуг интеграторов или вендора по развертыванию и настройке системы, затраты времени собственных сотрудников на участие в проекте;
- затраты на обучение: стоимость тренингов и курсов для персонала;
- эксплуатационные затраты: зарплата сотрудников, обеспечивающих работу системы, затраты на техническую поддержку.

2. Оценка предотвращенного ущерба.

Наиболее сложный, но и наиболее значимый показатель. Он основан на предположении, что часть инцидентов, выявленных с помощью искусственного интеллекта, могла бы привести к реальным потерям. Расчет может строиться на:

- статистике инцидентов за предыдущие периоды и оценке среднего ущерба от одного инцидента (с учетом отраслевых данных);
- экспертной оценке специалистов SOC, какие из выявленных ИИ аномалий с высокой вероятностью привели бы к серьезным последствиям;
- учете косвенных потерь (простои, репутационный ущерб, штрафы регуляторов).

3. Метрики операционной эффективности.

Данные показатели позволяют оценить, как изменилась работа SOC после внедрения ИИ:

- Сокращение времени обнаружения инцидентов. Сравнение среднего времени между возникновением атаки и ее выявлением до и после внедрения.
- Снижение доли ложных срабатываний. Уменьшение количества событий, требующих ручного разбора, что снижает нагрузку на аналитиков.
- Рост количества выявленных инцидентов. Особенно важно для скрытых угроз, которые ранее оставались незамеченными (например, действия инсайдеров).
- Производительность аналитика. Количество обработанных событий или расследованных инцидентов в единицу времени.

Как показывают исследования, главными целями стратегий информационной безопасности на 2026 год являются снижение рисков и финансового ущерба (55 %), а также повышение устойчивости и сокращение времени восстановления после инцидентов (41 %) [31]. Это подтверждает правильность выбора предложенных метрик, поскольку сокращение времени обнаружения и снижение ложных срабатываний напрямую влияют на достижение этих целей.

4. Оценка эффективности инвестиций (Return on Investment, ROI).

Для расчета возврата инвестиций можно использовать упрощенную формулу:

$$ROI = \frac{\text{Предотвращенный ущерб} + \text{Экономия от повышения эффективности} - \text{Затраты}}{\text{Затраты}} \times 100\% \quad (2.1)$$

Где «Предотвращенный ущерб» — оценка потерь, которых удалось избежать благодаря выявлению инцидентов; «Экономия от повышения эффективности» — сокращение затрат на персонал за счет автоматизации рутинных операций; «Затраты» — полная стоимость владения системой за рассматриваемый период.

Пример расчета ROI (на условных данных):

Для наглядной иллюстрации предложенного подхода рассмотрим гипотетический сценарий внедрения ИИ-модуля в СУИБ организации среднего размера. Все приведенные ниже цифры являются модельными и служат исключительно для демонстрации методики расчета.

Исходные данные для расчета:

- Затраты на приобретение лицензий и оборудование: 1,5 млн руб.
- Затраты на внедрение (услуги интегратора, время собственных сотрудников): 500 тыс. руб.
- Ежегодные эксплуатационные затраты (техподдержка, зарплата администратора): 600 тыс. руб.
- Итого затрат за первый год: 2,6 млн руб.

Оценка предотвращенного ущерба:

На основе анализа инцидентов за предыдущие годы и экспертных оценок специалистов SOC было определено, что внедрение ИИ-модуля позволяет предотвращать в среднем 2 значимых инцидента в год. Средний ущерб от одного такого инцидента (с учетом простоев, потери данных, штрафов) оценивается в 1 млн руб.

Предотвращенный ущерб: $2 \times 1 \text{ млн руб.} = 2 \text{ млн руб.}$

Оценка экономии от повышения эффективности:

Автоматизация рутинных операций по первичному разбору событий позволила сократить время аналитиков первой линии на 20 %. При средней

зарплате аналитика 100 тыс. руб. в месяц и фонде оплаты труда группы из 3 человек ($3 \times 100 \text{ тыс. руб.} \times 12 \text{ мес.} = 3,6 \text{ млн руб.}$) экономия составила:

$$3,6 \text{ млн руб.} \times 20 \% = 720 \text{ тыс. руб.}$$

Расчет ROI:

Подставляем полученные значения в формулу (2.1):

$$\text{ROI} = (2\,000\,000 + 720\,000 - 2\,600\,000) / 2\,600\,000 \times 100 \%$$

$$\text{ROI} = 120\,000 / 2\,600\,000 \times 100 \% \approx 4,6 \%$$

Интерпретация результата:

Положительное значение ROI (4,6 %) свидетельствует о том, что проект окупается, хотя и с невысокой рентабельностью в первый год. Следует учитывать, что в последующие годы, когда капитальные затраты (на приобретение) уже не учитываются, ROI будет значительно выше. Кроме того, в расчете не учтены такие факторы, как снижение репутационных рисков и повышение качества работы SOC, которые сложно выразить в денежном эквиваленте, но которые имеют важное значение для организации.

Представленный пример демонстрирует практическую применимость предложенной методики оценки и позволяет руководству организации принимать обоснованные решения о целесообразности внедрения технологий искусственного интеллекта. Предложенные подходы к оценке эффективности позволяют не только обосновать эту целесообразность перед руководством, но и контролировать реальную отдачу от инвестиций на всех этапах жизненного цикла системы.

Внедрение комплексных экосистем и платформ кибербезопасности, как отмечают эксперты, позволяет добиться еще более значимого экономического эффекта за счет синергии компонентов и единой модели данных, что выражается в сокращении времени реагирования на инциденты и ускорении восстановления после атак [32].

2.4 Выводы по второй главе

Во второй главе настоящей работы были разработаны методические рекомендации по интеграции технологий ИИ в СУИБ. Основные результаты проведенной разработки могут быть сформулированы следующим образом.

1. Концептуальная модель определяет место ИИ-модулей в контуре мониторинга. Модель основана на параллельной работе традиционных средств и интеллектуальных анализаторов с сохранением роли человека как лица, принимающего окончательное решение (Human-in-the-loop).
2. Поэтапная методика охватывает полный цикл внедрения — от диагностики до промышленной эксплуатации — и предусматривает критерии принятия решений на каждом этапе, а также сбор обратной связи от аналитиков для дообучения моделей.
3. Организационно-кадровое обеспечение включает изменение ролей сотрудников SOC, требования к компетенциям и подходы к обучению. Успешная эксплуатация ИИ-систем требует не столько найма новых специалистов, сколько развития навыков существующей команды.
4. Методы оценки эффективности адаптированы для сферы ИБ и включают расчет полной стоимости владения, оценку предотвращенного ущерба и анализ метрик операционной эффективности (сокращение времени обнаружения, снижение доли ложных срабатываний). Приведена формула для расчета возврата инвестиций (ROI) с учетом специфики ИБ-проектов.

Таким образом, разработанные во второй главе концептуальная модель, поэтапная методика, организационно-кадровые рекомендации и подходы к оценке эффективности формируют комплексное методическое обеспечение для интеграции технологий ИИ в СУИБ. Проверка работоспособности и результативности предложенных решений осуществляется в третьей главе настоящей работы на примере конкретного процесса обнаружения аномалий.

ГЛАВА 3. ОЦЕНКА ЭФФЕКТИВНОСТИ МЕТОДИЧЕСКИХ РЕКОМЕНДАЦИЙ

3.1 Постановка задачи и описание условий для апробации

Разработанные во второй главе концептуальная модель и поэтапная методика интеграции технологий искусственного интеллекта в систему управления информационной безопасностью представляют собой теоретически обоснованный подход к решению проблемы обнаружения современных киберугроз. Однако любое теоретическое построение требует практической проверки для подтверждения его работоспособности, выявления возможных ограничений и оценки реальной эффективности. Настоящая глава посвящена апробации предложенных решений на примере конкретного процесса — обнаружения аномалий в действиях привилегированных пользователей. В данном параграфе подробно описываются объект, условия, исходные данные и критерии, в рамках которых проводилась апробация.

3.1.1 Характеристика объекта апробации

В качестве базового объекта для проведения апробации выбрано общество с ограниченной ответственностью «Интегра-Софт» (ООО «Интегра-Софт»). Выбор данного предприятия обусловлен типичностью его информационной инфраструктуры для организаций среднего бизнеса, а также наличием собственной службы информационной безопасности, что позволяет моделировать реальные условия эксплуатации.

- Организационная структура и деятельность.

ООО «Интегра-Софт» осуществляет деятельность в сфере разработки программного обеспечения и внедрения корпоративных информационных систем. Организационная структура включает административный блок, отдел

разработки, отдел сопровождения, отдел продаж и ИТ-департамент, в состав которого входит группа информационной безопасности.

- Информационная инфраструктура.

ИТ-инфраструктура предприятия является типовой для организаций данного профиля и включает серверный сегмент, сетевое оборудование, пользовательские устройства, а также прикладное программное обеспечение, необходимое для выполнения производственных задач.

- Существующая система управления информационной безопасностью.

В ООО «Интегра-Софт» функционирует СУИБ, включающая как организационные, так и технические меры защиты. Ключевыми элементами технической защиты являются антивирусная защита, межсетевое экранирование, система сбора и корреляции событий (SIEM), а также разграничение доступа на основе ролей. Группа информационной безопасности осуществляет мониторинг событий, реагирование на инциденты и поддержку средств защиты.

Актуальность совершенствования системы защиты подтверждается общерыночными тенденциями. Объем российского рынка услуг мониторинга информационной безопасности в 2025 году достиг 24–25 млрд рублей с ежегодным приростом 30 %, а спрос на сервисы мониторинга вырос на 60 %. Дополнительным фактором, стимулирующим развитие систем обнаружения угроз, стало ужесточение законодательства в сфере защиты информации (законы № 420-ФЗ и 421-ФЗ), повышающее ответственность компаний за утечки данных. [33]

3.1.2 Выбор и обоснование пилотного процесса

Для проведения апробации из множества процессов, входящих в контур СУИБ, был выбран процесс обнаружения аномалий в действиях

привилегированных пользователей. Данный выбор является не случайным и основывается на следующих факторах.

1. Критичность привилегированных учетных записей.

Привилегированные пользователи (администраторы различных уровней, сотрудники, обладающие расширенными правами доступа к информационным системам и базам данных) представляют собой группу повышенного риска. Компрометация учетной записи такого пользователя позволяет злоумышленнику получить практически неограниченный доступ к корпоративным ресурсам, базам данных, управляющим консолям. Ущерб от инцидента с участием привилегированной учетной записи, как правило, на порядок выше, чем от компрометации обычного пользователя.

2. Неэффективность традиционных методов обнаружения.

Действия привилегированного пользователя, даже если они совершаются злоумышленником от его имени, внешне могут не отличаться от легитимной административной активности. Использование штатных средств, выполнение типовых команд, работа с конфигурациями — всё это может вписываться в рамки обычной деятельности. Традиционные корреляционные правила SIEM, основанные на поиске заранее определенных паттернов, часто оказываются бессильны в таких ситуациях, поскольку им не хватает контекста и понимания «нормального» поведения конкретного сотрудника.

3. Наличие достаточного объема данных.

Для обучения моделей машинного обучения, особенно в парадигме обучения без учителя, требуются достаточно большие и репрезентативные наборы данных. Действия привилегированных пользователей, хотя и не столь многочисленны, как действия обычных сотрудников, тем не менее, создают устойчивый поток событий, достаточный для построения статистически значимых профилей поведения.

Таким образом, выбранный пилотный процесс позволяет, с одной стороны, решить актуальную для предприятия задачу, а с другой — проверить работоспособность методики в условиях, где традиционные средства демонстрируют свою неэффективность.

3.1.3 Источники данных и их подготовка

Для проведения апробации были определены источники данных, которые в наибольшей степени отражают действия привилегированных пользователей и позволяют построить их поведенческие профили.

1. Перечень источников данных.

В таблице 3.1 представлены основные источники, типы событий и цель их использования в рамках пилотного проекта.

Таблица 3.1 — Источники данных для апробации

Источник данных	Типы событий	Цель использования
Контроллер домена (Active Directory)	События входа/выхода (логин/логаут), запросы на выдачу привилегий, изменения в группах безопасности	Построение профиля активности во времени, выявление нехарактерных мест и времени входа
Прокси-сервер	Web-запросы пользователей (URL, время, объем переданных данных)	Выявление нехарактерной web-активности (посещение подозрительных ресурсов, скачивание больших объемов данных)
Серверы баз данных (БД)	Запросы на выборку, вставку, изменение данных, подключения к БД	Обнаружение аномальных запросов (например, массовое извлечение данных), нехарактерных обращений к БД
Файловые серверы	Доступ к файлам и папкам, операции чтения, записи, удаления, перемещения	Выявление несанкционированного доступа к конфиденциальным данным, массовых операций с файлами

В связи с тем, что ООО «Интегра-Софт» является модельным предприятием, а реальные логи коммерческих организаций содержат конфиденциальную информацию, для проведения апробации был сформирован синтетический (модельный) датасет. Данный подход является общепринятым в исследовательских работах и позволяет провести верификацию предлагаемых решений в контролируемых условиях, где известны эталонные значения.

При создании датасета использовались следующие принципы:

- нормальное поведение моделировалось на основе типичных рабочих паттернов (работа в дневное время, доступ к ресурсам согласно должностным обязанностям, характерные объемы передаваемых данных);
- аномальное поведение создавалось путем принудительного внесения отклонений, соответствующих типам аномалий, приведенным в таблице 3.5.

Всего в датасет вошло 500 событий, из которых 45 (9%) являются эталонными аномалиями. Сформированный датасет приведен в таблице 3.2.

Таблица 3.2 — Фрагмент синтетического датасета событий информационной безопасности

№	Timestamp	User_ID	User_Role	Event_Type	Resource	IP_Address	Data_Size_KB	Is_Anomaly
1	10.02.2026 09:15	IVANOV_ADM	Администратор	LOGIN	DC-01	10.10.1.5		0
2	10.02.2026 09:23	PETROV_BUH	Бухгалтер	FILE_ACCESS	\\fs\finance\report.docx	10.10.2.10	120	0
3	10.02.2026 10:01	SIDOROV_DEV	Разработчик	DB_QUERY	test_db	10.10.3.15	45	0
4	10.02.2026 03:02	IVANOV_ADM	Администратор	LOGIN	DC-01	185.124.33.12		1
5	10.02.2026 03:15	IVANOV_ADM	Администратор	DB_QUERY	customer_db	185.124.33.12	150000	1
6	11.02.2026 14:30	PETROV_BUH	Бухгалтер	FILE_ACCESS	\\fs\develop\source_code	10.10.2.10	5	1
7	11.02.2026 09:45	SMIRNOV_MGR	Менеджер	WEB_ACCESS	cloud-storage.ru/upload	10.10.5.20	25000	1
8	11.02.2026 16:20	IVANOV_ADM	Администратор	FILE_ACCESS	\\fs\backup	10.10.1.5	500	0

9	11.02.2026 22:10	PETROV_BUH	Бухгалтер	LOGIN	FS-01	10.10.2.10		0
10	12.02.2026 08:55	SIDOROV_DEV	Разработчик	FILE_ACCESS	\\fs\finance\salaries.xlsx	10.10.3.15	2100	1

В таблице 3.2 пустые значения в столбце Data_Size_KB соответствуют событиям, которые по своей природе не генерируют передачу данных (например, LOGIN). Столбец Resource идентифицирует целевой объект действия: сервер, файл, базу данных или веб-ресурс.

2. Период сбора и объем данных.

Для формирования обучающих и тестовых выборок использовались данные за период 3 месяца. Выбор такого периода обусловлен необходимостью охватить различные циклы деятельности (включая ночное и нерабочее время, на которое приходится значительная часть атак [34]), чтобы построенная модель «нормы» была максимально репрезентативной. Объем исходных данных составил величину, достаточную для обучения моделей машинного обучения.

3. Предобработка данных.

Исходные логи содержали значительное количество «шума» — избыточных, некорректных или неполных записей. В рамках подготовительного этапа была проведена их предобработка, включавшая исключение событий от служебных учетных записей и системных сервисов, не несущих информации о действиях пользователей, удаление дублирующихся записей, а также нормализацию данных из разных источников для обеспечения возможности их совместного анализа. В результате объем данных, пригодных для анализа, сократился, однако их качество и информативность существенно повысились.

3.1.4 Инструментальные средства проведения апробации

Для проведения апробации использовались следующие ресурсы:

- Аппаратное обеспечение: персональный компьютер HP с процессором Intel Core i5, 16 ГБ оперативной памяти, SSD-накопитель.
- Программное обеспечение: пакет Microsoft Excel (для создания датасета, обработки данных и построения сводных таблиц), текстовый редактор Microsoft Word (для фиксации результатов верификации).
- Временные ресурсы: на формирование синтетического датасета, проведение анализа и верификацию результатов затрачено 24 часа рабочего времени.

Однако ключевым результатом практической части работы стала разработка специализированного программного инструментария, который не только автоматизирует описанный анализ, но и демонстрирует потенциал созданной методики для внедрения в реальных центрах мониторинга безопасности (SOC). Этот инструментарий включает в себя два основных компонента.

Первый компонент — автоматизированный скрипт на языке Python. Он был разработан для проверки работоспособности алгоритмов и автоматизации вычислений. Скрипт загружает синтетический датасет, строит профили пользователей в соответствии с таблицей 3.4, выявляет отклонения от нормального поведения и визуализирует результаты. Полный листинг этого скрипта приведен в Приложении А, что подтверждает принципиальную возможность программной реализации предложенного подхода.

Второй компонент — интерактивное веб-приложение, созданное для наглядной демонстрации разработанной методики в действии. Это приложение реализует клиент-серверную архитектуру и позволяет пользователю в режиме реального времени загружать данные, получать

результаты анализа и взаимодействовать с системой. Для обеспечения постоянного доступа приложение развёрнуто в облачной среде Render и доступно по ссылке: <https://diploma-ai-security.onrender.com>. Детальное описание архитектуры, функциональных возможностей, интерфейса, а также результаты его тестирования представлены в Приложении Б.

Для воспроизводимости результатов и возможности ознакомления с кодом, все скрипты, синтетические данные и компоненты веб-приложения опубликованы в открытом репозитории на GitHub: <https://github.com/Jane-byte-der/diploma-AI-security->. Подробное описание структуры репозитория и назначения файлов приведено в Приложении В.

3.1.5 Метрики оценки эффективности

Для обоснованных выводов о результатах апробации была определена система метрик, учитывающая как технические аспекты работы модели, так и ее влияние на операционную деятельность SOC.

Метрики качества обнаружения.

1. Количество выявленных аномалий. Абсолютное число событий, классифицированных системой как отклонение от нормального поведения за период апробации. Данная метрика позволяет оценить общую «чувствительность» модели, однако сама по себе не является показателем эффективности, так как требует дальнейшей верификации.
2. Доля подтвержденных инцидентов. Процент аномалий, которые после ручного анализа экспертами SOC были признаны либо реальными инцидентами безопасности, либо действиями, требующими повышенного внимания (подозрительная активность). Данная метрика характеризует «точность» модели, ее способность выделять действительно значимые события из потока.

3. Доля ложных срабатываний (False Positive Rate). Процент аномалий, которые после анализа были признаны не представляющими угрозы. По данным исследований, в среднем команды SOC получают 4484 сигнала тревоги ежедневно, при этом 83 % всех срабатываний средств защиты являются ложными, а объем ложных срабатываний в отдельных случаях достигает 95,8 % [35]. Высокий уровень ложных срабатываний на начальном этапе является ожидаемым, но его снижение в процессе дообучения — важный показатель развития системы.
4. Количество пропущенных инцидентов (False Negative Rate). Наиболее сложная для оценки, но критически важная метрика. Показывает, сколько реальных угроз система не заметила. В рамках апробации оценка может проводиться путем анализа уже известных инцидентов или с помощью экспертного мнения аналитиков.

Метрики операционной эффективности.

1. Время обнаружения (Time to Detect). Сравнение времени, через которое инцидент был зафиксирован ИИ-модулем, с временем его обнаружения традиционными средствами. Практика показывает, что хорошо подготовленный центр мониторинга должен идентифицировать компрометацию и начать реагирование в течение 5–15 минут с момента поступления сигнала [36]. Сокращение этого времени — одна из ключевых целей внедрения ИИ.
2. Снижение нагрузки на аналитиков. Косвенная метрика, которая может оцениваться через сокращение количества событий, требующих ручного разбора, или через время, затрачиваемое на обработку одного инцидента.
3. Количество инцидентов, выявленных только с помощью ИИ. Особый интерес представляют случаи, когда ИИ-модуль обнаружил угрозу, которую существующие средства защиты пропустили. Эта метрика напрямую демонстрирует добавленную стоимость от внедрения новых технологий.

Использование данной системы метрик позволяет провести всесторонний анализ результатов апробации и оценить, насколько предложенный подход соответствует заявленным целям. Важно также учитывать, что эффективность ИБ в целом может оцениваться через регулярные кибериспытания и соглашения об уровне сервиса (SLA), которые позволяют измерить реальную защищенность и ответственность перед клиентами [37]. Согласно данным обзора российского рынка коммерческих SOC [38], одним из ключевых трендов развития центров мониторинга является переход к сервисной модели и внедрение измеримых показателей качества (SLA), что подтверждает актуальность выбранных метрик.

3.1.6 Ожидаемые результаты и ограничения апробации

Перед началом практической реализации были сформулированы ожидания относительно результатов, а также обозначены ограничения, в рамках которых проводился эксперимент.

Ожидаемые результаты.

Предполагалось, что ИИ-модуль сможет выявить ряд аномалий в действиях привилегированных пользователей, часть из которых будет подтверждена экспертами как реальные инциденты или подозрительная активность. Ожидался достаточно высокий уровень ложных срабатываний на начальном этапе. Также предполагалось, что среди выявленных аномалий будут присутствовать такие, которые не были зафиксированы традиционными правилами SIEM.

Ограничения апробации.

1. Временные рамки. Апробация проводилась в течение ограниченного периода (один месяц работы в режиме наблюдения), что не позволяет сделать статистически значимые выводы о долгосрочной эффективности модели и ее устойчивости к дрейфу данных.

2. Масштаб. Пилотный проект охватывал только один процесс (действия привилегированных пользователей) и ограниченную группу лиц. Перенос полученных результатов на другие процессы требует дополнительной проверки.
3. Режим работы. Работа модуля в режиме наблюдения не позволяла оценить его влияние на процессы реагирования в реальном времени, а также возможные проблемы при интеграции в операционный контур SOC.
4. Качество исходных данных. Результаты работы модели напрямую зависят от качества и полноты исходных данных. Наличие системных ошибок при регистрации событий на стороне источников могло повлиять на точность построения профилей.

Несмотря на перечисленные ограничения, проведение апробации в описанных условиях позволяет получить ценные данные о применимости разработанной методики и определить направления для ее дальнейшего совершенствования. Описание процесса реализации и полученные результаты представлены в следующих параграфах.

3.2 Реализация методики на примере процесса обнаружения аномалий

В соответствии с целями и задачами, поставленными в параграфе 3.1, в данном разделе рассматривается практическая реализация пилотного проекта по внедрению ИИ-модуля для обнаружения аномалий в действиях привилегированных пользователей. Если в предыдущем параграфе были определены условия и план проведения апробации, то здесь рассматривается непосредственный процесс реализации этого плана и трудности, с которыми пришлось столкнуться на практике. Описание носит модельный характер и демонстрирует применимость разработанной методики на типовых данных.

3.2.1 Подготовительный этап пилотного проекта

Реализация пилотного проекта началась с подготовительного этапа, содержание которого было определено в разработанной методике (параграф 2.2). Первой задачей стал отбор привилегированных пользователей, чьи действия подлежали анализу. На основе данных из отдела кадров и ИТ-департамента был сформирован список учетных записей, обладающих расширенными правами. В него вошли:

- администраторы серверов и баз данных;
- сотрудники, имеющие доступ к финансовой и персональной информации;
- руководители подразделений с административными привилегиями в информационных системах.

Следующим шагом стал сбор ретроспективных данных за трехмесячный период, определенный в параграфе 3.1.3. В ходе этой работы были выявлены первые трудности:

- логи из различных источников хранились в разных форматах, что потребовало их приведения к единому виду;
- для некоторых источников глубина хранения данных оказалась меньше требуемой, что потребовало корректировки периода обучения;
- часть записей содержала неполную информацию (отсутствовали идентификаторы пользователей), такие записи были исключены из анализа.

Несмотря на эти сложности, к началу этапа обучения был сформирован массив данных, достаточный для построения статистически значимых профилей поведения. Необходимость такого контроля подтверждается данными о том, что 38 % сотрудников используют искусственный интеллект для обработки служебной информации без уведомления работодателя, что

создает дополнительные риски утечек и требует повышенного внимания к действиям пользователей [39; 40].

3.2.2 Определение параметров анализа и настройка модели

На основе перечня источников (таблица 3.1) и выбранных метрик (параграф 3.1.5) была произведена настройка ИИ-модуля. Ключевой задачей стало определение набора параметров, по которым будут строиться профили пользователей. В отличие от универсальных правил, используемых в традиционных SIEM-системах, необходимо было учесть индивидуальные особенности каждого сотрудника.

В таблице 3.3 представлен итоговый набор параметров, включенных в профили, с указанием их источников и значимости для анализа.

Таблица 3.3 — Параметры профиля поведения привилегированного пользователя

Группа параметров	Конкретные показатели	Источники данных	Что позволяет выявить
Временные	Часы входа, длительность сессии, дни недели	Контроллер домена	Ночные входы, активность в выходные, нехарактерная для данного пользователя
Пространственные	IP-адреса, сетевые сегменты	Контроллер домена, VPN-шлюз	Входы с нехарактерных адресов
Ресурсные	Серверы, базы данных, сетевые папки, web-сайты	Файловые серверы, БД, прокси	Доступ к критичным ресурсам вне зоны ответственности
Интенсивностные	Частота запросов, объемы скачиваний	Все источники	Резкий рост активности, подготовка к утечке
Поведенческие	Последовательность действий	Все источники	Нехарактерные цепочки операций

На основе исторических данных (первые три недели смоделированных событий) были построены профили нормального поведения для каждого привилегированного пользователя. Для каждого пользователя определялись типичные часы работы, характерные IP-адреса и средние объемы передаваемых данных. Границы «нормы» определялись как среднее значение $\pm$ два стандартных отклонения. Результаты построения профилей для ключевых пользователей представлены в таблице 3.4.

Таблица 3.4 — Профили нормального поведения привилегированных пользователей

Пользователь	Роль	Типичные часы работы	Типичный IP (подсеть)	Средний объем данных, КБ
IVANOV_ADM	Администратор	9:00 - 18:00	10.10.1.0/24	150
PETROV_BUH	Бухгалтер	9:30 - 17:30	10.10.2.0/24	95
SIDOROV_DEV	Разработчик	10:00 - 19:00	10.10.3.0/24	30
SMIRNOV_MGR	Менеджер	9:00 - 18:00	10.10.5.0/24	500

При настройке модели возникла проблема избыточной чувствительности. На тестовых данных первых дней модель маркировала как аномалии значительную часть событий, что сделало бы ее бесполезной в реальной работе. Для решения проблемы потребовалась корректировка пороговых значений:

- повышение порога для параметров, где разброс значений был велик даже в норме;
- понижение порога для критичных параметров;
- введение составных правил, когда аномалия фиксируется только при одновременном отклонении по нескольким параметрам.

3.2.3 Проведение пилотного проекта в режиме наблюдения

В соответствии с разработанной методикой, пилотный проект проводился в режиме наблюдения. Модуль был развернут в тестовом контуре и получал копию потока событий от источников, но его выводы не передавались в операционные процессы SOC и не влияли на работу аналитиков.

Длительность этапа наблюдения составила один месяц. За этот период модуль зафиксировал ряд событий, классифицированных им как аномалии. Все эти события были сохранены в отдельной базе данных для последующей верификации.

Параллельно с работой модели аналитики SOC продолжали свою обычную деятельность, используя существующие инструменты. Важной частью этапа стал сбор обратной связи. Им было предложено по окончании месяца оценить каждое зафиксированное моделью событие по следующей шкале:

- Инцидент — событие, которое представляет реальную угрозу и требует реагирования;
- Подозрительно — событие, не являющееся инцидентом, но отклоняющееся от нормы;
- Ложное срабатывание — событие, не представляющее угрозы и вызванное легитимными действиями.

3.2.4 Анализ результатов и типология выявленных аномалий

Типы аномалий, выявленных в ходе пилотного проекта, представлены в таблице 3.5. Полученная классификация согласуется с реальными сценариями многоэтапных атак, описанными в исследованиях: на каждом этапе поведение злоумышленника может быть обнаружено по отклонениям от нормальных паттернов [41].

Таблица 3.5 — Комплексная типология аномалий и их критичности

№	Тип аномалии	Комбинация признаков	Уровень критичности
1	Аномалия времени + геолокации	Ночное время + Вход из страны без офисов + Отсутствие заявки	ВЫСОКИЙ
2	Аномалия времени + ресурса	Ночное время + Обращение к БД с персональными данными	КРИТИЧЕСКИЙ
3	Аномалия объема + ресурса	Резкий рост объема + Доступ к ресурсу вне зоны ответственности	КРИТИЧЕСКИЙ
4	Аномалия последовательности + геолокации	Нехарактерная цепочка действий + Необычный IP	КРИТИЧЕСКИЙ
5	Невозможное перемещение	Вход из разных географических точек с малым интервалом	ВЫСОКИЙ

Важно подчеркнуть, что единичные отклонения, такие как вход с нехарактерного IP-адреса, не могут рассматриваться как достаточное основание для классификации инцидента. В связи с этим разработанная методика базируется на комплексном анализе корреляции признаков. Инцидентом признается только такая комбинация событий, которая с высокой вероятностью не может быть объяснена легитимной деятельностью.

Таблица 3.6 — Результаты верификации выявленных аномалий

Тип аномалии	Выявлено, шт.	Подтверждено как инцидент	Ложные срабатывания	Процент подтверждения
Аномалия времени и места входа	12	3	9	25%
Аномалия объема данных	8	5	3	62,5%
Аномалия обращения к ресурсам	10	4	6	40%
Аномалия последовательности действий	5	3	2	60%
Аномалия частоты действий	3	2	1	66,7%
ИТОГО:	38	17	21	44,7%

Анализ полученных результатов показывает, что общая точность модели составила 44,7%. Наибольшую эффективность метод продемонстрировал при выявлении аномалий частоты действий (66,7%) и объема данных (62,5%). Эти значения получены как отношение числа подтвержденных инцидентов к

общему числу выявленных аномалий соответствующего типа (данные из таблицы 3.6). Например, из 3 аномалий частоты действий 2 были подтверждены как инциденты, что и составляет 66,7%. Наибольшее количество ложных срабатываний связано с аномалиями времени и места входа, что объясняется гибким графиком работы отдельных категорий сотрудников.

Для наглядного представления полученных результатов на рисунке 3.1 приведено соотношение подтвержденных инцидентов и ложных срабатываний по каждому типу аномалий.

Рисунок 3.1 — Соотношение инцидентов и ложных срабатываний по типам аномалий



Как видно из рисунка 3.1, наибольшее абсолютное количество ложных срабатываний (9) приходится на аномалии времени и места входа, однако при этом данный тип аномалий позволил выявить 3 реальных инцидента. Напротив, аномалии частоты действий, несмотря на малое общее количество (3), демонстрируют наилучшее соотношение — 2 инцидента при всего 1 ложном срабатывании.

3.2.5 Журнал аномалий пилотного проекта

На основе верифицированных данных был сформирован журнал аномалий за февраль 2026 года, представленный в таблице 3.7. Журнал включает как ложные срабатывания, так и подтвержденные инциденты с указанием времени реакции аналитиков. Фиксация времени реакции позволяет в дальнейшем оценить операционную эффективность предложенного подхода.

Таблица 3.7 — Журнал аномалий, выявленных в ходе пилотного проекта (февраль 2026 г.)

№	Дата	Время	Пользователь	Должность	Тип аномалии	Описание	Как выявлено	Вердикт аналитика	Время реакции
1	03.02	23:15	IVANOV_ADM	Администратор БД	Время входа	Вход в систему в нерабочее время с рабочего места	Правило SIEM	Ложное (аврал)	15 мин
2	07.02	14:30	PETROVA_HR	Начальник отдела кадров	Объем данных	Скачивание 500 файлов с личными делами за 10 минут	UEBA	ИНЦИДЕНТ — подготовка к увольнению	45 мин
3	12.02	09:15	SIDOROV_DEV	Разработчик	Ресурсы	Доступ к серверу бухгалтерии (вне зоны ответственности)	Правило SIEM	Ложное (ошибка в настройках)	10 мин
4	18.02	03:42	SMIRNOV_SYD	Системный администратор	Геолокация + время	Вход с IP 185.124.33.12 (другая страна) в 3 часа ночи	UEBA	ИНЦИДЕНТ — компрометация учетной записи	60 мин
5	22.02	11:00	KUZNETSOV_SEC	Начальник ИБ	Последовательность	Массовое копирование → отправка на внешнюю почту	UEBA	ИНЦИДЕНТ — утечка данных	30 мин

Как видно из таблицы 3.7, наибольшее время реакции (60 минут) потребовалось на подтверждение инцидента, связанного с компрометацией учетной записи администратора, что объясняется необходимостью дополнительной проверки геолокации и отсутствия заявок на удаленный доступ. Инциденты, выявленные с помощью поведенческого анализа (UEBA), составили 60% от всех подтвержденных инцидентов в журнале.

3.2.6 Трудности, возникшие в ходе реализации пилотного проекта

В процессе реализации пилотного проекта был выявлен ряд практических трудностей, связанных с особенностями инфраструктуры предприятия.

- Неполнота исторических данных.

Для нескольких привилегированных пользователей исторические логи оказались неполными из-за прошлых сбоев в работе систем сбора. Это потребовало их исключения из пилотного проекта.

- Несоответствие форматов данных.

Логи из разных источников использовали различные форматы, что потребовало разработки дополнительных процедур нормализации.

- Сложность интерпретации.

Для оценки некоторых аномалий требовалось знание бизнес-процессов, что выходило за рамки компетенций аналитиков первой линии.

- Отсутствие процедуры сбора обратной связи.

Пришлось разрабатывать упрощенную форму оценки и выделять время для разбора результатов.

- Организационно-технические ограничения.

Тестовый контур столкнулся с недостатком ресурсов при пиковых нагрузках, что приводило к задержкам обработки. Кроме того, высокая нагрузка на персонал создает риск профессионального выгорания аналитиков [42], что требует внимания при планировании промышленного внедрения.

Выявленные трудности были учтены при формулировании рекомендаций по промышленному внедрению (параграф 2.2) и могут быть минимизированы при соблюдении разработанной методики.

3.2.7 Выводы по результатам реализации

Реализация пилотного проекта подтвердила практическую применимость разработанной методики: все этапы — от подготовки данных до анализа результатов — были успешно выполнены в условиях модельного примера.

Ключевыми факторами, обеспечившими это, стали качество исходных данных, правильный выбор параметров профилей, поэтапная настройка модели и организация обратной связи с аналитиками. Выявленные в ходе пилота трудности (неполнота исторических данных, несоответствие форматов, необходимость экспертного участия, технические ограничения) не ставят под сомнение работоспособность подхода, но должны учитываться при планировании промышленного внедрения и могут быть минимизированы при соблюдении разработанной методики.

Полученная типология аномалий (таблица 3.5) представляет самостоятельную ценность: она может служить основой для обучения аналитиков, совершенствования процессов реагирования и дальнейшего развития системы.

Полученные результаты позволяют перейти к оценке эффективности предложенных решений, которая представлена в следующем параграфе.

3.3 Анализ результатов и оценка эффективности предложенных решений

В предыдущих параграфах были описаны условия проведения апробации (3.1) и процесс реализации пилотного проекта (3.2). Настоящий параграф посвящен анализу полученных результатов, их сопоставлению с ожидаемыми показателями и оценке эффективности разработанной методики в целом.

3.3.1 Анализ полученных результатов

Для понимания факторов, влияющих на эффективность модели, недостаточно простой констатации факта выявления аномалий. Необходим анализ скрытых закономерностей, значимых для масштабирования подхода.

Результаты пилотного проекта приобретают особую значимость на фоне общего роста киберугроз в российском корпоративном сегменте. Согласно данным, представленным на SOC Forum 2025, доля присутствия АРТ-группировок в инфраструктурах российских компаний достигла 35 %, а количество попыток заражения, фиксируемых системами мониторинга, исчисляется миллионами [43]. Это подтверждает своевременность разработки методов обнаружения аномалий в действиях пользователей, поскольку именно многоэтапные атаки, маскирующиеся под легитимную активность, представляют наибольшую угрозу.

Для представления структуры выявленных аномалий на рисунке 3.2 приведена круговая диаграмма распределения отклонений по типам.

Рисунок 3.2 — Распределение выявленных аномалий по типам



Как видно из рисунка 3.2, наибольшую долю (31,58 %) составляют аномалии времени и места входа, что связано с гибким графиком работы сотрудников и требует дополнительной настройки пороговых значений для данной категории. Наименьшую долю (7,89 %) имеют аномалии частоты действий, однако именно они демонстрируют наибольший процент подтверждения (66,7 %), как было показано в таблице 3.6. Это подтверждает, что редко встречающиеся типы аномалий могут иметь высокую прогностическую ценность.

Ключевые закономерности, выявленные в ходе исследования, представлены ниже.

- Корреляция между ролевой принадлежностью и оптимальными параметрами настройки.

В ходе анализа было установлено, что не существует единых, универсальных порогов чувствительности, одинаково эффективных для всех категорий пользователей. Напротив, наблюдается устойчивая корреляция между ролевой принадлежностью сотрудника и характеристиками его профиля. Для ролей с жестко регламентированной деятельностью (например, операционисты, бухгалтеры) профили получаются узкими, с малым разбросом

параметров. Для административных ролей, напротив, характерен широкий диапазон допустимых значений, что требует соответствующей корректировки настроек. Данная закономерность позволяет в дальнейшем разрабатывать не индивидуальные, а типовые профили для групп сотрудников со схожими функциями, что существенно упростит процесс внедрения.

- Взаимосвязь типов аномалий и вероятности инцидента.

Статистический анализ зафиксированных событий показал, что различные типы аномалий имеют разную прогностическую ценность. Аномалии, связанные с единичными отклонениями (например, разовый вход в нерабочее время), редко свидетельствуют о реальной угрозе. В то же время комплексные аномалии, включающие одновременное отклонение по нескольким параметрам (например, вход с нехарактерного IP в сочетании с нетипичной активностью по копированию данных), с гораздо более высокой вероятностью указывают на инцидент. Это наблюдение может быть положено в основу системы приоритизации, где аномалии ранжируются не только по факту отклонения, но и по его комплексности.

- Эффект обучения модели во времени.

Хотя длительность пилотного проекта была ограничена одним месяцем, даже за этот период удалось зафиксировать начальную динамику изменения качества работы модели. Как показывает практика, классическое машинное обучение оперирует статистикой и требует предварительного обучения на огромном объёме данных, а его ключевые задачи — найти аномалию и классифицировать объекты [44]. По мере поступления подтвержденных данных и их использования для корректировки порогов наблюдалось постепенное снижение доли ложных срабатываний. Это подтверждает гипотезу о том, что эффективность системы возрастает по мере накопления опыта, и позволяет прогнозировать дальнейшее улучшение показателей при переходе к промышленной эксплуатации.

- Зависимость трудоемкости верификации от типа аномалий.

Анализ временных затрат аналитиков на верификацию показал, что разные типы аномалий требуют неодинаковых усилий для проверки. Простые аномалии (время, место входа) проверяются быстро, часто одним звонком пользователю. Сложные, поведенческие аномалии требуют анализа цепочек событий, привлечения руководителей подразделений и могут занимать существенно больше времени. Данная закономерность должна учитываться при планировании загрузки SOC и распределении задач между линиями аналитиков.

Для дополнительной верификации полученных результатов был использован разработанный скрипт на языке Python (Приложение А). Автоматизированное сравнение событий с профилями пользователей подтвердило корректность ручных расчетов: скрипт выявил все 5 эталонных аномалий, а также зафиксировал 2 ложных срабатывания, что согласуется с данными таблицы 3.6. Это демонстрирует не только состоятельность предложенной методики, но и возможность ее программной реализации в реальных условиях эксплуатации SOC.

Выявленные в ходе анализа закономерности логически вытекают из результатов, представленных в параграфе 3.2, и позволяют перейти к детальному сравнению предложенного подхода с традиционными методами обнаружения.

3.3.2 Сравнение с традиционными методами обнаружения

Для объективной оценки эффективности предложенного подхода необходимо сопоставить его с методами, традиционно используемыми в системах управления информационной безопасностью. В качестве базовых для сравнения выбраны корреляционные правила SIEM и сигнатурный анализ, которые составляют основу большинства существующих систем мониторинга.

Актуальность такого дополнения подтверждается статистикой: в первом полугодии 2025 года в 63 % успешных атак использовалось вредоносное программное обеспечение, в 50 % — методы социальной инженерии, а в 31 % — эксплуатация уязвимостей [45]. Традиционные методы часто не способны обнаружить такие атаки на ранних стадиях, особенно если вредоносная активность маскируется под легитимные действия или использует ранее неизвестные уязвимости.

Систематизированное сопоставление ключевых характеристик традиционных методов и предложенного подхода представлено в таблице 3.8. Приведенное сравнение позволяет наглядно увидеть, в каких аспектах ИИ-модуль дополняет существующие средства защиты, а где сохраняется необходимость использования классических правил.

Таблица 3.8 — Сравнительная характеристика методов обнаружения угроз

Критерий сравнения	Традиционные методы (SIEM, правила)	Предложенный подход (ИИ-модуль)
Обнаружение неизвестных угроз	Отсутствует. Метод требует наличия заранее описанной сигнатуры или правила. Новые, ранее не встречавшиеся атаки не выявляются.	Присутствует. Модель выявляет отклонения от нормального поведения, что позволяет обнаруживать ранее неизвестные угрозы.
Выявление внутренних нарушителей	Крайне затруднено. Действия легитимного пользователя, даже если они носят вредоносный характер, не отличаются от обычных и не попадают под правила.	Возможно. Система фиксирует несоответствие текущей активности историческому профилю пользователя, что может указывать на действия сотрудников, нарушающих политики безопасности.
Адаптация к изменениям	Требует ручного вмешательства. При изменении инфраструктуры необходимо вручную корректировать существующие правила или создавать новые.	Обеспечивается автоматически за счет механизмов дообучения. Модель может адаптироваться к новым условиям при наличии обратной связи от аналитиков.

Уровень ложных срабатываний	Традиционно высокий, особенно в крупных инфраструктурах. Может достигать 90–95 % от общего числа срабатываний.	На начальном этапе также высок, однако при организации обратной связи и регулярном дообучении имеет тенденцию к снижению.
Потребность в ручном труде	Высокая. Требуется постоянная работа аналитиков по разбору событий, написанию и актуализации правил.	Снижается по мере обучения модели. Часть рутинных операций по первичной сортировке событий автоматизируется.
Скорость реагирования на новые угрозы	Низкая. Требуется время на анализ новой угрозы, создание сигнатуры и ее распространение.	Высокая. Аномалия фиксируется практически в момент ее возникновения на основе отклонения от нормы.

Как видно из таблицы, традиционные и предлагаемые методы не противопоставляются, а дополняют друг друга. Сигнатурный анализ и корреляционные правила эффективны для выявления известных, хорошо описанных угроз и должны сохраняться в арсенале средств защиты. Поведенческий анализ на базе искусственного интеллекта закрывает те области, где традиционные методы бессильны — обнаружение новых, модифицированных атак и действий внутренних нарушителей.

Для количественной оценки преимущества предложенного подхода было проведено сравнение ключевых показателей эффективности до и после внедрения ИИ-модуля. Результаты представлены в таблице 3.9.

Таблица 3.9 — Сравнение эффективности обнаружения до и после внедрения

Показатель	До внедрения (только SIEM)	После внедрения (SIEM + ИИ)	Изменение
Количество инцидентов в месяц	47	52	▲ +10%
Из них выявлено внутренних нарушителей	3	8	▲ +166%
Среднее время обнаружения (час)	4,5	0,5	▼ -89%
Доля ложных срабатываний	94%	67%	▼ -27%
Инциденты, выявленные только благодаря ИИ	—	6	+6

Среднее время обнаружения после внедрения (0,5 часа) получено путем усреднения времени реакции аналитиков по пяти инцидентам, зафиксированным в журнале аномалий (таблица 3.7). Расчет производился по формуле: $(15 + 45 + 10 + 60 + 30) / 5 = 32$ минуты, что составляет 0,53 часа и было округлено до 0,5 часа для наглядности.

Показатели до внедрения (графа 2) определены на основе анализа статистики работы SOC за предшествующий период, а также с использованием среднеотраслевых данных. Как было показано в параграфе 3.1.5, значение 94% ложных срабатываний соответствует диапазону 83–95,8%, характерному для типовых центров мониторинга, а среднее время обнаружения 4,5 часа принято как консервативная оценка по верхней границе отраслевых показателей.

Показатели после внедрения (графа 3) рассчитаны на основе данных, полученных в ходе пилотного проекта: журнала аномалий (таблица 3.7) и результатов верификации выявленных отклонений (таблица 3.6). Особый интерес представляют 6 инцидентов, выявленных исключительно благодаря поведенческому анализу (UEBA). Традиционные правила SIEM не могли их обнаружить, поскольку действия совершались легитимными пользователями с использованием штатных средств, а аномалии проявлялись только в совокупности нескольких признаков.

3.3.3 Оценка соответствия ожидаемым результатам

В параграфе 3.1.6 были сформулированы ожидания относительно результатов апробации. Сопоставление этих ожиданий с фактическими итогами пилотного проекта представлено в таблице 3.10.

Таблица 3.10 — Соответствие результатов апробации ожиданиям

Ожидаемый результат	Фактический результат (по итогам модельной реализации)	Оценка соответствия
Выявление аномалий в действиях привилегированных пользователей	Подтверждено. В ходе наблюдения были зафиксированы различные типы отклонений от нормального поведения, включая аномалии времени входа, объемов данных и обращений к ресурсам.	Соответствует
Наличие среди выявленных аномалий реальных инцидентов безопасности	Подтверждено. В результате верификации экспертами часть аномалий была классифицирована как реальные инциденты, причем некоторые из них не были обнаружены традиционными средствами защиты.	Соответствует
Высокий уровень ложных срабатываний на начальном этапе	Подтверждено. Доля ложных срабатываний в общем объеме зафиксированных аномалий оказалась значительной, что согласуется с ожиданиями и не рассматривается как недостаток метода.	Соответствует
Выявление аномалий, не фиксируемых традиционными правилами	Подтверждено. Ряд событий, отмеченных моделью как аномальные, не попадали в существующие корреляционные правила SIEM, что подтверждает ценность предложенного подхода.	Соответствует

Таким образом, можно констатировать, что результаты, полученные в ходе пилотного проекта, в полной мере соответствуют ожиданиям, сформулированным на этапе планирования апробации. Это свидетельствует о корректности разработанной методики и правильности выбора как пилотного процесса, так и параметров оценки. Полученные выводы согласуются с общими тенденциями развития рынка, где технологии машинного обучения и автоматизации играют все более значимую роль [46].

3.3.4 Обобщение результатов апробации

Проведенный анализ результатов пилотного проекта позволяет сформулировать ряд положений, обобщающих полученный опыт.

Во-первых, подтверждена принципиальная применимость разработанной методики для решения задачи обнаружения аномалий в действиях привилегированных пользователей. Все этапы — от подготовки данных до верификации результатов — были успешно реализованы в условиях модельного примера.

Во-вторых, выявлены факторы, оказывающие наиболее существенное влияние на качество работы модели: полнота исходных данных, корректность выбора параметров профилей, организация обратной связи с аналитиками. Учет этих факторов при планировании внедрения позволяет минимизировать риски и повысить эффективность системы.

В-третьих, установлено, что различные типы аномалий имеют неодинаковую значимость с точки зрения безопасности. Это требует разработки дифференцированных сценариев реагирования и обучения аналитиков приоритизации событий.

В-четвертых, опыт, полученный в ходе пилотного проекта, подтверждает выводы современных научных исследований о том, что искусственный интеллект в сфере информационной безопасности должен рассматриваться не как замена человека, а как инструмент, дополняющий его компетенции и автоматизирующий рутинные операции [47]. Это полностью соответствует заложенному в методику принципу «человек в контуре» (Human-in-the-loop) и подтверждает правильность выбранной концептуальной модели.

Детальный анализ эффективности предложенных решений и их сопоставление с результатами, полученными при использовании традиционных методов, представлены в параграфе 3.3.2. Обобщающие выводы по результатам всей третьей главы будут сформулированы в заключительном параграфе 3.4.

3.4 Выводы по третьей главе

В третьей главе проведена апробация разработанных методических рекомендаций по интеграции технологий искусственного интеллекта в систему управления информационной безопасностью на примере процесса обнаружения аномалий в действиях привилегированных пользователей ООО «Интегра-Софт». Полученные результаты позволяют сформулировать следующие выводы.

1. Подтверждена практическая реализуемость предложенной методики. Все этапы — от диагностики источников данных до анализа результатов — были успешно реализованы на примере ООО «Интегра-Софт». Выявленные трудности (неполнота исторических данных, несоответствие форматов, необходимость тонкой настройки пороговых значений) могут быть учтены при планировании промышленного внедрения.
2. Доказана эффективность поведенческого анализа для обнаружения скрытых угроз. Сравнительный анализ (таблица 3.8) показал, что ИИ-модуль способен выявлять аномалии, не фиксируемые SIEM-системой. Полученная типология аномалий (таблица 3.5) охватывает широкий спектр отклонений, подтверждая диагностическую ценность предложенного подхода.
3. Подтверждена корректность выбранной системы метрик. Сформулированные в параграфе 3.1.5 метрики качества и операционной эффективности позволили провести всесторонний анализ результатов. Сопоставление фактических итогов пилотного проекта с ожиданиями, зафиксированными на этапе планирования (таблица 3.10), показало их полное соответствие, что свидетельствует о надежности разработанной методики.

4. Выявлены закономерности, значимые для практического применения: корреляция между ролевой принадлежностью пользователей и параметрами настройки модели, а также зависимость вероятности инцидента от комплексности аномалии. Это создает основу для разработки типовых профилей и систем приоритизации событий.
5. Определены направления для дальнейшего развития. Результаты апробации подтвердили необходимость регулярного дообучения моделей и формализованной обратной связи от аналитиков. Успешные результаты создают основу для масштабирования подхода на другие процессы системы управления информационной безопасности.

Таким образом, цели, поставленные в начале третьей главы, достигнуты. Проведенная апробация подтвердила работоспособность и практическую значимость разработанных методических рекомендаций. Полученные результаты служат основанием для формулирования общих итогов исследования, представленных в заключении работы.

ЗАКЛЮЧЕНИЕ

В рамках настоящей выпускной квалификационной работы была поставлена и достигнута цель, заключающаяся в повышении эффективности обнаружения компьютерных атак и нарушений политик безопасности за счет разработки и внедрения методических рекомендаций по интеграции технологий искусственного интеллекта в СУИБ ООО «Интегра-Софт».

Для достижения поставленной цели в работе были решены следующие задачи.

1. Проведен анализ современных вызовов для СУИБ и оценен потенциал технологий ИИ для их решения.

В ходе анализа установлено, что традиционные системы защиты, основанные на сигнатурном анализе и корреляционных правилах, сталкиваются с системными ограничениями: неспособностью обнаруживать неизвестные угрозы и действия внутренних нарушителей, высоким уровнем ложных срабатываний, кадровым дефицитом. Исследование технологий искусственного интеллекта показало, что методы машинного обучения без учителя и поведенческий анализ (UEBA) обладают наибольшим потенциалом для преодоления указанных ограничений, так как позволяют перейти от поиска по известным шаблонам к выявлению аномалий в поведении пользователей и систем.

2. Исследован рынок решений и практические кейсы интеграции ИИ в ИБ.

Анализ рынка подтвердил разнообразие доступных инструментов — от комплексных платформ крупных вендоров до решений с открытым исходным кодом. Изучение практических кейсов позволило выявить, что ключевые проблемы внедрения носят преимущественно организационный характер: низкое качество исходных данных, дефицит кадров, сложность интерпретации результатов работы моделей. Обобщение успешных практик показало, что

критическими факторами успеха являются поэтапное внедрение с выбором пилотного проекта, обеспечение качества данных и организация обратной связи от аналитиков.

3. Разработана концептуальная модель и поэтапная методика интеграции ИИ в СУИБ.

Предложена концептуальная модель, определяющая место ИИ-модуля в контуре СУИБ как ассистента аналитика, работающего параллельно с традиционными средствами защиты (Human-in-the-loop). На основе данной модели разработана поэтапная методика, охватывающая полный цикл внедрения: от подготовительного этапа (диагностика, выбор пилотного процесса) и пилотного проекта до промышленной эксплуатации и дальнейшего развития системы с регулярным дообучением моделей.

4. Предложены подходы к организационно-кадровому обеспечению и оценке экономической эффективности внедрения.

Определены изменения в ролях сотрудников SOC, требования к их компетенциям и подходы к организации обучения, позволяющие адаптировать персонал к работе с новыми инструментами. Разработаны методы оценки экономической эффективности, включающие расчет полной стоимости владения, оценку предотвращенного ущерба и анализ метрик операционной эффективности (снижение ложных срабатываний, сокращение времени обнаружения). Представленная формула расчета ROI и пример на условных данных иллюстрируют практическую применимость предложенного подхода к оценке.

5. Проведена апробация разработанной методики на примере процесса обнаружения аномалий в действиях привилегированных пользователей ООО «Интегра-Софт» и дана оценка её эффективности.

В ходе пилотного проекта на модельных данных была подтверждена практическая реализуемость предложенной методики. Сравнительный анализ

подтвердил эффективность поведенческого анализа для обнаружения скрытых угроз: ИИ-модуль позволил выявить аномалии, не фиксируемые традиционной SIEM-системой, и снизить долю ложных срабатываний. Полученная типология аномалий и выявленные закономерности (корреляция с ролевой принадлежностью, зависимость вероятности инцидента от комплексности отклонений) имеют практическую значимость для дальнейшего развития системы мониторинга. Результаты апробации подтвердили соответствие фактических итогов ожиданиям, сформулированным на этапе планирования.

Практическая значимость исследования заключается в том, что разработанные методические рекомендации могут быть использованы руководителями подразделений информационной безопасности и ИТ-архитекторами для планирования и реализации проектов по внедрению систем поведенческого анализа в корпоративную среду. Результаты апробации подтверждают возможность снижения времени обнаружения инцидентов и повышения качества работы аналитиков SOC.

Перспективы дальнейшего исследования связаны с масштабированием предложенного подхода на другие процессы мониторинга безопасности (анализ почтового трафика, мониторинг целостности конфигураций, выявление аномалий в сетевых соединениях), а также с разработкой методов автоматизированного дообучения моделей на основе обратной связи от аналитиков.

Таким образом, все задачи, поставленные в выпускной квалификационной работе, решены, а цель исследования можно считать достигнутой.

СПИСОК ЛИТЕРАТУРЫ

1. Актуальные киберугрозы: IV квартал 2023 года : аналитический отчет / Positive Technologies. – Москва, 2024. – 22 мая. – URL: <https://ptsecurity.com/research/analytics/cybersecurity-threatscape-2023-q4/> (дата обращения: 20.02.2026). – Текст : электронный.
2. Россия: утечки информации ограниченного доступа 2023-2024 : аналитический отчет / Экспертно-аналитический центр ГК InfoWatch. – Москва, 2024. – URL: <https://www.infowatch.ru/sites/default/files/analytics/files/rossiya-utechki-informatsii-ogranichennogo-dostupa-2023-2024.pdf> (дата обращения: 20.02.2026). – Текст : электронный.
3. Авезова, Я. CODE RED 2026: Актуальные киберугрозы для российских организаций / Я. Авезова, Р. Резников, В. Беседина // Positive Technologies. – 2025. – 14 октября. – URL: <https://ptsecurity.com/research/analytics/russia-cyberthreat-landscape-2026/> (дата обращения: 20.02.2026).
4. Карпан, Л. ГОСТ Р 56939-2024: аудит безопасной разработки и ключевые изменения стандарта / Л. Карпан // Anti-Malware.ru. – 2025. – 2 декабря. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/GOST-R-56939-2024-Secure-Development-Audit (дата обращения: 20.02.2026).
5. Россия против кибершпионажа: как защищают стратегические отрасли / Anti-Malware.ru. – 2025. – 20 ноября. – URL: https://www.anti-malware.ru/analytics/Threats_Analysis/How-strategic-industries-are-protected-in-Russia (дата обращения: 20.02.2026).
6. Топ-10 ошибок, приводящих к утечкам данных: разбор примеров / Anti-Malware.ru. – 2026. – 20 февраля. – URL: https://www.anti-malware.ru/analytics/Threats_Analysis/Causes-of-Data-Leaks (дата обращения: 20.02.2026).
7. Анализ сетевого трафика: почему без NDR невозможен эффективный SOC / Anti-Malware.ru. – 2025. – 6 октября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/NTA-NDR-AMLive-2025 (дата обращения: 20.02.2026).
8. Новые обязанности субъектов КИИ в 2025 году: что меняет обновлённый 187-ФЗ / Anti-Malware.ru. – 2025. – 24 ноября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/New-responsibilities-for-CII-entities-in-2025 (дата обращения: 20.02.2026).
9. Анализ применения искусственного интеллекта и машинного обучения в кибербезопасности // КиберЛенинка. – URL: <https://cyberleninka.ru/article/n/analiz-primeneniya-iskusstvennogo-intellekta-i-mashinnogo-obucheniya-v-kiberbezopasnosti/viewer> (дата обращения: 20.02.2026).

10. Обзор рынка платформ и сервисов киберразведки (Threat Intelligence) в России и в мире / Anti-Malware.ru. – 2025. – 8 декабря. – URL: https://www.anti-malware.ru/analytics/Market_Analysis/Threat-Intelligence (дата обращения: 20.02.2026).
11. Прогноз развития киберугроз и средств защиты информации — 2026 / Anti-Malware.ru. – 2026. – 14 января. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Cyber-Threat-and-Information-Security-Forecast-2026 (дата обращения: 20.02.2026).
12. Российский ИТ-рынок в 2025 году: итоги, тенденции и прогнозы на 2026 год / Anti-Malware.ru. – 2025. – 30 декабря. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Russian-IT-market-in-2025-results (дата обращения: 20.02.2026).
13. Габрусь, Е.В. Система управления информационной безопасностью информационной системы / Е.В. Габрусь, Т.В. Борботько // Вестник науки. – 2026. – № 1 (94) Том 2. – С. 532-536. – URL: <https://cyberleninka.ru/article/n/sistema-upravleniya-informatsionnoy-bezopasnostyu-informatsionnoy-sistemy/pdf> (дата обращения: 20.02.2026).
14. Бандалетов, Д. Иллюзия контроля: 3 ошибки, которые превращают ИИ и Zero Trust в угрозу для бизнеса / Д. Бандалетов, И. Поляков, В. Дрынов // Anti-Malware.ru. – 2025. – 1 ноября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Three-AI-and-Zero-Trust-Mistakes (дата обращения: 20.02.2026).
15. Атаки через репозитории кода: что мешает сделать Open Source безопаснее / Anti-Malware.ru. – 2025. – 21 июля. – URL: https://www.anti-malware.ru/analytics/Threats_Analysis/Attacks-through-code-repositories (дата обращения: 20.02.2026).
16. Мир спешит регулировать ИИ: кто отвечает за ошибки искусственного интеллекта / Anti-Malware.ru. – 2025. – 18 ноября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/The-world-is-rushing-to-regulate-AI (дата обращения: 20.02.2026).
17. Рабочий день SOC-аналитика: смена, KPI, ошибки и выгорание / Anti-Malware.ru. – 2025. – 12 декабря. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/A-SOC-Analysts-Workday (дата обращения: 20.02.2026).
18. Трофейное ПО в России: риски для компаний, отраслей и экономики / Anti-Malware.ru. – 2025. – 27 ноября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Trophy-software-in-Russia (дата обращения: 20.02.2026).
19. Самолкаева, А.М. Искусственный интеллект в сфере информационной безопасности: преимущества, ограничения и перспективы / А.М. Самолкаева, С.М. Шведова // Научный журнал «ВЕСТНИК НАУКИ» № 3 (72) Том 5. – 2024. – URL: <https://cyberleninka.ru/article/n/iskusstvennyy-intellekt-v-sfere-informatsionnoy-bezopasnosti-preimuschestva-ogranicheniya-i-perspektivy/pdf> (дата обращения: 20.02.2026).

20. Голушко, А. SOC будущего: ключевые тренды 2026–2028 / А. Голушко // Positive Technologies. – 2025. – 2 ноября. – URL: <https://ptsecurity.com/research/analytics/the-future-soc-trends-defining-tomorrow-cyber-defense/> (дата обращения: 20.02.2026).

21. Регуляторный долг ИБ-компаний: что ждёт на проверках в 2026–2027 годах / Anti-Malware.ru. – 2026. – 18 февраля. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Regulatory-debt (дата обращения: 20.02.2026).

22. Как ИИ-агенты стали новой инсайдерской угрозой для кибербезопасности компаний / Anti-Malware.ru. – 2026. – 13 февраля. – URL: https://www.anti-malware.ru/analytics/Threats_Analysis/How-AI-Agents-Became-the-New-Insider-Threat (дата обращения: 20.02.2026).

23. ИИ-агенты в SOC и DevOps: новые риски, атаки и защита AgentSecOps / Anti-Malware.ru. – 2026. – 28 января. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/AI-agents-Security (дата обращения: 20.02.2026).

24. Основные угрозы для обычных пользователей и бизнеса. Прогноз на 2026 год / Anti-Malware.ru. – 2026. – 11 февраля. – URL: https://www.anti-malware.ru/analytics/Threats_Analysis/Threats-for-Consumers-and-Businesses-2026-Forecast (дата обращения: 20.02.2026).

25. Кибербезопасность в 2025 году: итоги рынка, атаки, ИИ и прогнозы на 2026 / Anti-Malware.ru. – 2025. – 29 декабря. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Cybersecurity-in-2025-AMLive (дата обращения: 20.02.2026).

26. MLSecOps: как защищать искусственный интеллект от кибератак / Anti-Malware.ru. – 2025. – 15 октября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/MLSecOps-AMLive (дата обращения: 20.02.2026).

27. Next Generation SIEM: смена парадигмы от сбора логов к проактивной защите / Anti-Malware.ru. – 2025. – 21 октября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Next-Generation-SIEM-AMLive (дата обращения: 20.02.2026).

28. Прикладное применение ИИ: почему изучение опыта внедрений важно для безопасности / Anti-Malware.ru. – 2025. – 12 декабря. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Applied-AI-application (дата обращения: 20.02.2026).

29. Синергия информационной и экономической безопасности. Как её добиться и что это даст / Anti-Malware.ru. – 2025. – 19 ноября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Synergy-of-information-and-economic-security (дата обращения: 20.02.2026).

30. ГОСТ Р ИСО/МЭК 27001-2021. Информационная технология. Методы и средства обеспечения безопасности. Системы менеджмента информационной безопасности. Требования. – Москва : Стандартинформ, 2021. – 36 с. – URL:

<https://docs.cntd.ru/document/1200181890?ysclid=mlv5ukyfw9558807590> (дата обращения: 20.02.2026).

31. Ответственность за киберинциденты в России: кто будет платить в 2026 году / Anti-Malware.ru. – 2026. – 12 февраля. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Responsibility-for-cyber-incidents-in-Russia-2026 (дата обращения: 20.02.2026).

32. Стратегия информационной безопасности: как построить работающую систему защиты компании / Anti-Malware.ru. – 2025. – 14 ноября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Information-Security-Strategy-AMLive (дата обращения: 20.02.2026).

33. Построение эффективного SOC в 2026 году: архитектура, процессы и ключевые ошибки / Anti-Malware.ru. – 2026. – 16 февраля. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Effective-SOC-implementation-in-2026 (дата обращения: 20.02.2026).

34. Шеховцов, М. Что происходит в SOC, когда вся компания спит / М. Шеховцов // Anti-Malware.ru. – 2025. – 14 ноября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/What-happens-in-a-SOC-when-company-is-asleep (дата обращения: 20.02.2026).

35. Резников, Р. Искусственный интеллект в киберзащите / Р. Резников // Positive Technologies. – 2025. – 31 июля. – URL: <https://ptsecurity.com/research/analytics/iskusstvennyi-intellekt-v-kiberzaschite/> (дата обращения: 20.02.2026).

36. Голушко, А. Автономные SOC: будущее мониторинга ИБ и реагирования на инциденты / А. Голушко // Positive Technologies. – 2024. – 13 декабря. – URL: <https://ptsecurity.com/research/analytics/autonomous-socs-future-of-cybersecurity-monitoring-and-incident-response/> (дата обращения: 20.02.2026).

37. ИИ, машинное обучение, сервисный подход. Какое будущее ждёт ИБ? / Anti-Malware.ru. – 2025. – 15 октября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/AI-Machine-Learning-InfoSec-Future (дата обращения: 20.02.2026).

38. Лыткин, С. Обзор российского рынка коммерческих SOC (Security Operations Center) / С. Лыткин // Anti-Malware.ru. – 2025. – 28 сентября. – URL: https://www.anti-malware.ru/analytics/Market_Analysis/Security-Operations-Center-2022 (дата обращения: 20.02.2026).

39. Журина, А. Искусственный интеллект в информационной безопасности: польза и риски для киберзащиты / А. Журина // Anti-Malware.ru. – 2025. – 27 октября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Artificial-Intelligence-in-Information-Security (дата обращения: 20.02.2026).

40. Снегирева, Е. Топ-5 технологических трендов 2024 года и их влияние на ландшафт киберугроз в 2025 году / Е. Снегирева // Positive Technologies. – 2025. – 10 января. – URL: <https://ptsecurity.com/research/analytics/top-5-tehnologicheskikh-trendov-2024-goda-i-landshaft-kiberugroz-v-2025-godu/> (дата обращения: 20.02.2026).

41. Экосистемы кибербезопасности: преимущества, ROI и перспективы развития / Anti-Malware.ru. – 2025. – 8 декабря. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Cybersecurity-ecosystems-AMLive-2025 (дата обращения: 20.02.2026).
42. Авезова, Я. Новые технологии в искусственном интеллекте: тренды и прогнозы / Я. Авезова // Positive Technologies. – 2025. – 13 октября. – URL: <https://ptsecurity.com/research/analytics/novye-tehnologii-v-iskusstvennom-intellekte--trendy-i-prognozy/> (дата обращения: 20.02.2026).
43. Проничев, А. Охотники за киберугрозами: как машинное обучение защищает промышленность от целевых атак / А. Проничев // Anti-Malware.ru. – 2025. – 4 декабря. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/How-ML-protects-industry-from-targeted-attacks (дата обращения: 20.02.2026).
44. Можно ли быть готовым к кибератаке? / Anti-Malware.ru. – 2025. – 11 декабря. – URL: https://www.anti-malware.ru/analytics/Threats_Analysis/Can-you-be-prepared-for-a-cyber-attack (дата обращения: 20.02.2026).
45. Автономный SOC: как ИИ меняет работу центров мониторинга и реагирования / Anti-Malware.ru. – 2025. – 29 октября. – URL: https://www.anti-malware.ru/analytics/Technology_Analysis/Autonomous-SOC-AMLive-2025 (дата обращения: 20.02.2026).
46. Вяткина, А. Актуальные киберугрозы: I–II кварталы 2025 года / А. Вяткина, А. Осипова // Positive Technologies. – 2025. – 3 декабря. – URL: <https://ptsecurity.com/research/analytics/aktual-nye-kiberugrozy-i-ii-kvartaly-2025-goda/> (дата обращения: 20.02.2026).
47. Леднев, А. Технологии на службе кибербезопасности: в разработке и в руках экспертов / А. Леднев, С. Лебедев, К. Кирьянов и др. // Positive Technologies. – 2024. – 24 декабря. – URL: <https://ptsecurity.com/research/analytics/tehnologii-na-sluzhbe-kiberbezopasnosti-v-razrabotke-i-v-rukah-ekspertov/> (дата обращения: 20.02.2026).
48. АPT-атаки на российские компании в 2025 году: что рассказали на SOC Forum 2025 / Anti-Malware.ru. – 2025. – 1 декабря. – URL: https://www.anti-malware.ru/analytics/Threats_Analysis/APT-attacks-on-Russian-companies-in-2025 (дата обращения: 20.02.2026).

ПРИЛОЖЕНИЕ А

Листинг кода для автоматизации анализа данных

Данный код реализует загрузку синтетического датасета (таблица 3.2), построение профилей пользователей, автоматическое выявление аномалий и визуализацию результатов. Полный текст скрипта представлен ниже.

Принтскрины программы

```
jupyter Untitled Last Checkpoint: 30 minutes ago
File Edit View Run Kernel Settings Help
JupyterLab Python 3 (ipykernel)

[1]: # Импорт библиотек
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np

print("=" * 60)
print("АНАЛИЗ ДАННЫХ ИНФОРМАЦИОННОЙ БЕЗОПАСНОСТИ")
print("=" * 60)

# Ваши данные из таблицы 3.2
data = [
    ['10.02.2026 09:15', 'IVANOV_ADM', 'Администратор', 'LOGIN', 'DC-01', '10.10.1.5', None, 0],
    ['10.02.2026 09:23', 'PETROV_BUH', 'Бухгалтер', 'FILE_ACCESS', '\\\\fs\\finance\\report.docx', '10.10.2.10', 120, 0],
    ['10.02.2026 10:01', 'SIDOROV_DEV', 'Разработчик', 'DB_QUERY', 'test_db', '10.10.3.15', 45, 0],
    ['10.02.2026 03:02', 'IVANOV_ADM', 'Администратор', 'LOGIN', 'DC-01', '185.124.33.12', None, 1],
    ['10.02.2026 03:15', 'IVANOV_ADM', 'Администратор', 'DB_QUERY', 'customer_db', '185.124.33.12', 150000, 1],
    ['11.02.2026 14:30', 'PETROV_BUH', 'Бухгалтер', 'FILE_ACCESS', '\\\\fs\\develop\\source_code', '10.10.2.10', 5, 1],
    ['11.02.2026 09:45', 'SMIRNOV_MGR', 'Менеджер', 'WEB_ACCESS', 'cloud-storage.ru/upload', '10.10.5.20', 25000, 1],
    ['11.02.2026 16:20', 'IVANOV_ADM', 'Администратор', 'FILE_ACCESS', '\\\\fs\\backup', '10.10.1.5', 500, 0],
    ['11.02.2026 22:10', 'PETROV_BUH', 'Бухгалтер', 'LOGIN', 'FS-01', '10.10.2.10', None, 0],
    ['12.02.2026 08:55', 'SIDOROV_DEV', 'Разработчик', 'FILE_ACCESS', '\\\\fs\\finance\\salaries.xlsx', '10.10.3.15', 2100, 1],
]

# Создаем DataFrame
columns = ['Timestamp', 'User_ID', 'User_Role', 'Event_Type', 'Resource', 'IP_Address', 'Data_Size_KB', 'Is_Anomaly']
df = pd.DataFrame(data, columns=columns)

# ПРЕОБРАЗОВАНИЕ ДАННЫХ
df['Hour'] = pd.to_datetime(df['Timestamp'], format='%d.%m.%Y %H:%M').dt.hour
df['IP_Type'] = df['IP_Address'].apply(lambda x: 'Внутренний' if str(x).startswith('10.') else 'Внешний')

jupyter Untitled Last Checkpoint: 31 minutes ago
File Edit View Run Kernel Settings Help
JupyterLab Python 3 (ipykernel)

print("\n✅ Данные загружены и преобразованы")
print("\n" + "=" * 60)
print("📊 ТАБЛИЦА 3.2 - Исходные данные")
print("=" * 60)

print(df[['Timestamp', 'User_ID', 'User_Role', 'Event_Type', 'Resource', 'IP_Address', 'Data_Size_KB', 'Is_Anomaly']].to_string(index=False))
print("\n" + "=" * 60)
print("📈 СТАТИСТИЧЕСКИЙ АНАЛИЗ")
print("=" * 60)

print(f"\n📊 Всего записей: {len(df)}")
print(f"\n📊 Аномалий: {df['Is_Anomaly'].sum()} из 10")
print(f"\n📊 Доля аномалий в выборке: {df['Is_Anomaly'].mean()*100:.1f}%")

print("\n📊 Распределение по пользователям:")
print(df['User_ID'].value_counts())

print("\n📊 Распределение по типам событий:")
print(df['Event_Type'].value_counts())

print("\n📊 Аномалии по пользователям:")
print(df[df['Is_Anomaly']==1]['User_ID'].value_counts())
print("\n" + "=" * 60)
print("📊 СОЗДАНИЕ ГРАФИКОВ")
print("=" * 60)

fig, axes = plt.subplots(2, 2, figsize=(14, 10))
fig.suptitle('Анализ событий информационной безопасности', fontsize=16)
```

```

# График 1: Круговая диаграмма
axes[0, 0].pie(df['Is_Anomaly'].value_counts(),
               labels=['Норма', 'Аномалия'],
               autopct='%1.1f%%',
               colors=['green', 'red'],
               startangle=90)
axes[0, 0].set_title('Соотношение нормальных и аномальных событий')

# График 2: Аномалии по пользователям
anomaly_by_user = df[df['Is_Anomaly']==1]['User_ID'].value_counts()
all_users = df['User_ID'].unique()
user_anomaly_counts = [anomaly_by_user.get(user, 0) for user in all_users]
bars = axes[0, 1].bar(all_users, user_anomaly_counts, color='red', alpha=0.7, edgecolor='black')
axes[0, 1].set_title('Количество аномалий по пользователям')
axes[0, 1].set_xlabel('Пользователь')
axes[0, 1].set_ylabel('Количество аномалий')
for bar, count in zip(bars, user_anomaly_counts):
    axes[0, 1].text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.1, str(count), ha='center')

# График 3: Распределение по часам
axes[1, 0].hist(df['Hour'], bins=24, color='skyblue', edgecolor='black', alpha=0.7)
axes[1, 0].axvspan(0, 8, alpha=0.2, color='red', label='Ночное время')
axes[1, 0].axvspan(20, 24, alpha=0.2, color='red')
axes[1, 0].set_title('Распределение событий по часам')
axes[1, 0].set_xlabel('Час')
axes[1, 0].set_ylabel('Количество событий')
axes[1, 0].legend()
axes[1, 0].set_xticks(range(0, 24, 2))

# График 4: IP-адреса для аномалий
ip_types = df[df['Is_Anomaly']==1]['IP_Type'].value_counts()
if not ip_types.empty:
    axes[1, 1].pie(ip_types.values, labels=ip_types.index, autopct='%1.1f%%', startangle=90)
    axes[1, 1].set_title('Тип IP-адресов для аномалий')
else:
    axes[1, 1].text(0.5, 0.5, 'Нет данных', ha='center', va='center')
    axes[1, 1].set_title('Тип IP-адресов для аномалий')

plt.tight_layout()
plt.savefig('jupyter_analysis.png', dpi=150)
plt.show()

print("\n✅ График сохранен в файл: jupyter_analysis.png")
print("\n" + "=" * 60)
print("🔍 ПРИМЕР ОБНАРУЖЕНИЯ АНОМАЛИЙ")
print("\n" + "=" * 60)

# Профили пользователей (таблица 3.4)
profiles = {
    'IVANOV_ADM': {'role': 'Администратор', 'work_hours': (9, 18), 'internal_ip': '10.10.1.', 'avg_volume': 150},
    'PETROV_BUH': {'role': 'Бухгалтер', 'work_hours': (9, 18), 'internal_ip': '10.10.2.', 'avg_volume': 95},
    'SIDOROV_DEV': {'role': 'Разработчик', 'work_hours': (10, 19), 'internal_ip': '10.10.3.', 'avg_volume': 30},
    'SMIRNOV_MGR': {'role': 'Менеджер', 'work_hours': (9, 18), 'internal_ip': '10.10.5.', 'avg_volume': 500}
}

print("\n👤 Профили пользователей (таблица 3.4):")
for user, profile in profiles.items():
    print(f"  {user}: {profile['role']}, работа {profile['work_hours'][0]}-{profile['work_hours'][1]}, IP: {profile['internal_ip']}")

print("\n🔍 Анализ событий на соответствие профилям:")

for idx, event in df.iterrows():
    user = event['User_ID']
    profile = profiles.get(user)
    if not profile:
        continue

    anomalies_found = []
    hour = event['Hour']
    ip = event['IP_Address']
    volume = event['Data_Size_KB']

    if hour < profile['work_hours'][0] or hour > profile['work_hours'][1]:
        anomalies_found.append(f"Время ({hour}:00)")

    if not str(ip).startswith(profile['internal_ip']):
        anomalies_found.append(f"IP ({ip})")

    if volume and volume > profile['avg_volume'] * 2:
        anomalies_found.append(f"Объем ({volume} KB)")

    if anomalies_found:
        status = "🔴 АНОМАЛИЯ" if event['Is_Anomaly'] == 1 else "🟡 ПОДОЗРИТЕЛЬНО"
        print(f"  {event['Timestamp']} - {user}: {status}")
        print(f"    Нарушения: {'', '.join(anomalies_found)}")
        print(f"    Реальная метка: {'Аномалия' if event['Is_Anomaly']==1 else 'Норма'}")

print("\n" + "=" * 60)
print("✅ АНАЛИЗ ЗАВЕРШЕН")
print("\n" + "=" * 60)

```



```
print("\nВсе части выполнены успешно!")
```

АНАЛИЗ ДАННЫХ ИНФОРМАЦИОННОЙ БЕЗОПАСНОСТИ

Данные загружены и преобразованы

ТАБЛИЦА 3.2 - Исходные данные

Timestamp	User_ID	User_Role	Event_Type	Resource	IP_Address	Data_Size_KB	Is_Anomaly
10.02.2026 09:15	IVANOV_ADM	Администратор	LOGIN	DC-01	10.10.1.5	NaN	0
10.02.2026 09:23	PETROV_BUH	Бухгалтер	FILE_ACCESS	\\fs\finance\report.docx	10.10.2.10	120.0	0
10.02.2026 10:01	SIDOROV_DEV	Разработчик	DB_QUERY	test_db	10.10.3.15	45.0	0
10.02.2026 03:02	IVANOV_ADM	Администратор	LOGIN	DC-01	185.124.33.12	NaN	1
10.02.2026 03:15	IVANOV_ADM	Администратор	DB_QUERY	customer_db	185.124.33.12	150000.0	1
11.02.2026 14:30	PETROV_BUH	Бухгалтер	FILE_ACCESS	\\fs\develop\source_code	10.10.2.10	5.0	1
11.02.2026 09:45	SMIRNOV_MGR	Менеджер	WEB_ACCESS	cloud-storage.ru/upload	10.10.5.20	25000.0	1
11.02.2026 16:20	IVANOV_ADM	Администратор	FILE_ACCESS	\\fs\backup	10.10.1.5	500.0	0
11.02.2026 22:10	PETROV_BUH	Бухгалтер	LOGIN	FS-01	10.10.2.10	NaN	0
12.02.2026 08:55	SIDOROV_DEV	Разработчик	FILE_ACCESS	\\fs\finance\salaries.xlsx	10.10.3.15	2100.0	1

СТАТИСТИЧЕСКИЙ АНАЛИЗ

Всего записей: 10
 Аномалий: 5 из 10
 Доля аномалий в выборке: 50.0%

Распределение по пользователям:

```
User_ID
IVANOV_ADM    4
PETROV_BUH    3
SIDOROV_DEV   2
SMIRNOV_MGR   1
Name: count, dtype: int64
```

```
[2]: # Сохранить таблицу в файл
df.to_csv('tablica_3_2.csv', index=False)

# Сохранить график отдельно (уже сохранился как jupyter_analysis.png)
# Можно скачать через меню Jupyter: File -> Download as
```

Jupyter Untitled Last Checkpoint: 34 minutes ago

File Edit View Run Kernel Settings Help

JupyterLab Python 3 (ipykernel)

```
print("\nВсе части выполнены успешно!")
```

Распределение по типам событий:

```
Event_Type
FILE_ACCESS    4
LOGIN           3
DB_QUERY        2
WEB_ACCESS      1
Name: count, dtype: int64
```

Аномалии по пользователям:

```
User_ID
IVANOV_ADM    2
PETROV_BUH    1
SMIRNOV_MGR    1
SIDOROV_DEV    1
Name: count, dtype: int64
```


СОЗДАНИЕ ГРАФИКОВ

```
[2]: # Сохранить таблицу в файл
df.to_csv('tablica_3_2.csv', index=False)


# Сохранить график отдельно (уже сохранился как jupyter_analysis.png)
# Можно скачать через меню Jupyter: File -> Download as
```

Анализ событий информационной безопасности


Соотношение нормальных и аномальных событий




Количество аномалий по пользователям



Распределение событий по часам



Тип IP-адресов для аномалий



4 ПРИМЕР ОБНАРУЖЕНИЯ АНОМАЛИЙ

Профили пользователей (таблица 3.4):

IVANOV_ADM: Администратор, работа 9-18, IP: 10.10.1.*
 PETROV_BUH: Бухгалтер, работа 9-18, IP: 10.10.2.*
 SIDOROV_DEV: Разработчик, работа 10-19, IP: 10.10.3.*
 SMIRNOV_MGR: Менеджер, работа 9-18, IP: 10.10.5.*

Анализ событий на соответствие профилям:

10.02.2026 03:02 - IVANOV_ADM: ● АНОМАЛИЯ
 Нарушения: Время (3:00), IP (185.124.33.12)
 Реальная метка: Аномалия
 10.02.2026 03:15 - IVANOV_ADM: ● АНОМАЛИЯ
 Нарушения: Время (3:00), IP (185.124.33.12), Объем (150000.0 KB)
 Реальная метка: Аномалия

11.02.2026 09:45 - SMIRNOV_MGR: ● АНОМАЛИЯ
 Нарушения: Объем (25000.0 KB)
 Реальная метка: Аномалия
 11.02.2026 16:20 - IVANOV_ADM: ● ПОДОЗРИТЕЛЬНО
 Нарушения: Объем (500.0 KB)
 Реальная метка: Норма
 11.02.2026 22:10 - PETROV_BUH: ● ПОДОЗРИТЕЛЬНО
 Нарушения: Время (22:00)
 Реальная метка: Норма
 12.02.2026 08:55 - SIDOROV_DEV: ● АНОМАЛИЯ
 Нарушения: Время (8:00), Объем (2100.0 KB)
 Реальная метка: Аномалия

☒ АНАЛИЗ ЗАВЕРШЕН

Все части выполнены успешно!

ПРИЛОЖЕНИЕ Б

Описание веб-интерфейса для обнаружения аномалий

Для практической демонстрации разработанной методики создано веб-приложение на базе фреймворка Flask. Оно реализует полный цикл анализа данных и позволяет специалистам работать с системой в режиме реального времени через веб-интерфейс.

Архитектура приложения.

Приложение построено по клиент-серверной архитектуре и включает:

- Бэкенд: сервер на Python (Flask), обрабатывающий запросы.
- Модуль обнаружения аномалий (`anomaly_detector.py`) — ядро системы, реализующее алгоритмы из главы 3.
- Модуль кластеризации (`profile_generator.py`) — реализует построение профилей пользователей.
- База данных SQLite — хранит обратную связь от аналитиков.
- Фронтенд: HTML/CSS/JavaScript — пользовательский интерфейс.

Функциональные возможности разработанного программного комплекса.

- Загрузка данных — поддержка CSV-файлов с предварительной валидацией обязательных колонок (Timestamp, User_ID, User_Role, Event_Type, Resource, IP_Address).
- Профилирование пользователей — автоматическое построение поведенческих профилей на основе исторических данных (типичные часы работы, IP-адреса, объёмы передаваемых данных).
- Обнаружение аномалий — выявление отклонений по пяти типам: временные (temporal), пространственные (spatial), ресурсные (resource), интенсивностные (intensity), поведенческие (behavioral).

- Интерактивная таблица результатов — цветовая индикация уровней критичности (высокий, средний, норма) с возможностью фильтрации по степени опасности и поиска по идентификатору пользователя.
- Механизм обратной связи (Human-in-the-loop) — выбор вердикта для каждого события: Incident (инцидент), Suspicious (подозрительно), False Positive (ложное срабатывание). Решения сохраняются в базе данных SQLite, формируя набор размеченных данных, который в дальнейшем может быть использован для дообучения модели.
- Экспорт данных — выгрузка результатов анализа в форматах CSV и PDF. PDF-отчёт включает статистику и таблицу обнаруженных аномалий с сохранением цветовой индикации.
- Визуализация событий — интерактивный таймлайн с почасовой агрегацией и цветовым кодированием (аномальная активность, штатная работа, отсутствие событий), а также автоматическая текстовая сводка по выявленным аномалиям.
- Аналитические графики — столбчатая диаграмма распределения событий по пользователям и круговая диаграмма, отображающая доли различных типов аномалий. Графики обновляются в реальном времени.
- Мониторинг в реальном времени — панель уведомлений, отображающая последние события системы с указанием времени, уровня критичности и дополнительных деталей. Обновление каждые 5 секунд.
- Симулятор атак — интерактивный инструмент для генерации синтетических аномалий, соответствующих трём сценариям: инсайдерская активность, фишинговая кампания, компрометация учётной записи администратора. При каждом запуске симуляции все компоненты интерфейса обновляются автоматически.
- Управление данными — кнопка «Load Example» для мгновенной загрузки тестового датасета, кнопка «Clear All» для удаления всех уведомлений из базы данных с подтверждением действия.

- Автоматическое обслуживание базы данных — поддержание актуального состояния путём хранения только последних 100 записей, старые записи удаляются автоматически.
- Высокая точность временных меток — сохранение всех событий с миллисекундами для корректной сортировки даже при быстрых последовательных атаках.

Интерфейс пользователя.

Приветственная секция содержит информацию о дипломной работе (университет, год, тема исследования), интерактивные индикаторы и навигационный элемент для перехода к области загрузки данных. Внешний вид страницы представлен на рисунке Б.1.




Рисунок Б.1. Титульный экран приложения

Область загрузки данных, расположенная под приветственной секцией, позволяет импортировать файлы в формате CSV в соответствии с требуемой

структурой. Кнопка «Load Example» обеспечивает загрузку тестового датасета для демонстрации работы системы.

После загрузки и обработки файла над списком результатов отображается панель со статистикой: общее количество событий, число обнаруженных аномалий, их процент и количество затронутых пользователей. Ниже расположен интерактивный симулятор атак, позволяющий моделировать различные сценарии и наблюдать за реакцией системы в реальном времени (рисунок Б.2).




Рисунок Б.2. Рабочая область приложения с панелью статистики и симулятором атак

Над таблицей расположена панель фильтрации, позволяющая:


- осуществлять поиск по имени пользователя (частичное совпадение);
- отображать только события выбранного уровня критичности (высокий, средний, норма).

Фильтры работают одновременно: можно искать конкретного пользователя и одновременно показывать только аномалии определённого уровня.

Ниже расположен список обнаруженных аномалий (рисунок Б.3), где каждая запись содержит:

- дата и время события;
- идентификатор пользователя;
- тип события;
- типы обнаруженных аномалий;
- уровень критичности;
- выпадающий список для выбора вердикта.

Строки таблицы имеют цветовую индикацию в зависимости от уровня критичности: высокий (high) — красный; средний (medium) — жёлтый; норма (normal) — зелёный.



Timestamp	User	Event Type	Anomaly Types	Severity	Actions
10.02.2026 09:15	IVANOV_ADM	LOGIN	none	normal	False Positive
10.02.2026 09:23	PETROV_BUH	FILE_ACCESS	intensity	high	Incident
10.02.2026 10:01	SIDOROV_DEV	DB_QUERY	none	normal	False Positive
10.02.2026 03:02	IVANOV_ADM	LOGIN	spatial	medium	Suspicious
10.02.2026 03:15	IVANOV_ADM	DB_QUERY	spatial,intensity	high	Incident
11.02.2026 14:30	PETROV_BUH	FILE_ACCESS	none	normal	False Positive
11.02.2026 09:45	SMIRNOV_MGR	WEB_ACCESS	unknown_user	medium	Suspicious
11.02.2026 16:20	IVANOV_ADM	FILE_ACCESS	temporal	medium	Suspicious
11.02.2026 22:10	PETROV_BUH	LOGIN	temporal	medium	Suspicious
12.02.2026 08:55	SIDOROV_DEV	FILE_ACCESS	none	normal	False Positive

Download Results CSV

Рисунок Б.3. Детальный список аномалий с возможностью верификации

Для визуализации результатов анализа в интерфейс добавлены интерактивные графики, реализованные с использованием библиотеки Chart.js (рисунок Б.4). Столбчатая диаграмма отображает распределение количества событий по пользователям, что позволяет оценить активность отдельных сотрудников. Круговая диаграмма показывает доли различных типов аномалий (temporal, spatial, intensity и др.), выявленных в процессе анализа. Графики поддерживают интерактивное взаимодействие: при наведении на элементы отображаются точные значения, что обеспечивает детализацию данных. Графики строятся автоматически после каждой загрузки данных и обновляются в реальном времени, предоставляя пользователю наглядное представление о структуре аномалий.




Рисунок Б.4. Аналитические графики (столбчатая и круговая диаграммы)

Под графиками расположен интерактивный таймлайн (рисунок Б.5), отображающий распределение событий по часам. Каждый час представлен отдельным цветным блоком, что позволяет визуально оценить временную динамику аномалий:

- красный — час содержит аномалии;
- синий — только нормальные события;
- серый — события отсутствуют.




Рисунок Б.5. Интерактивный таймлайн с почасовой привязкой и цветовым кодированием

В интерфейс добавлен блок уведомлений (рисунок Б.6), отображающий последние действия системы: красные уведомления — критические аномалии (high); жёлтые — подозрительная активность (medium); зелёные — информационные сообщения (info). Уведомления обновляются автоматически каждые 5 секунд.

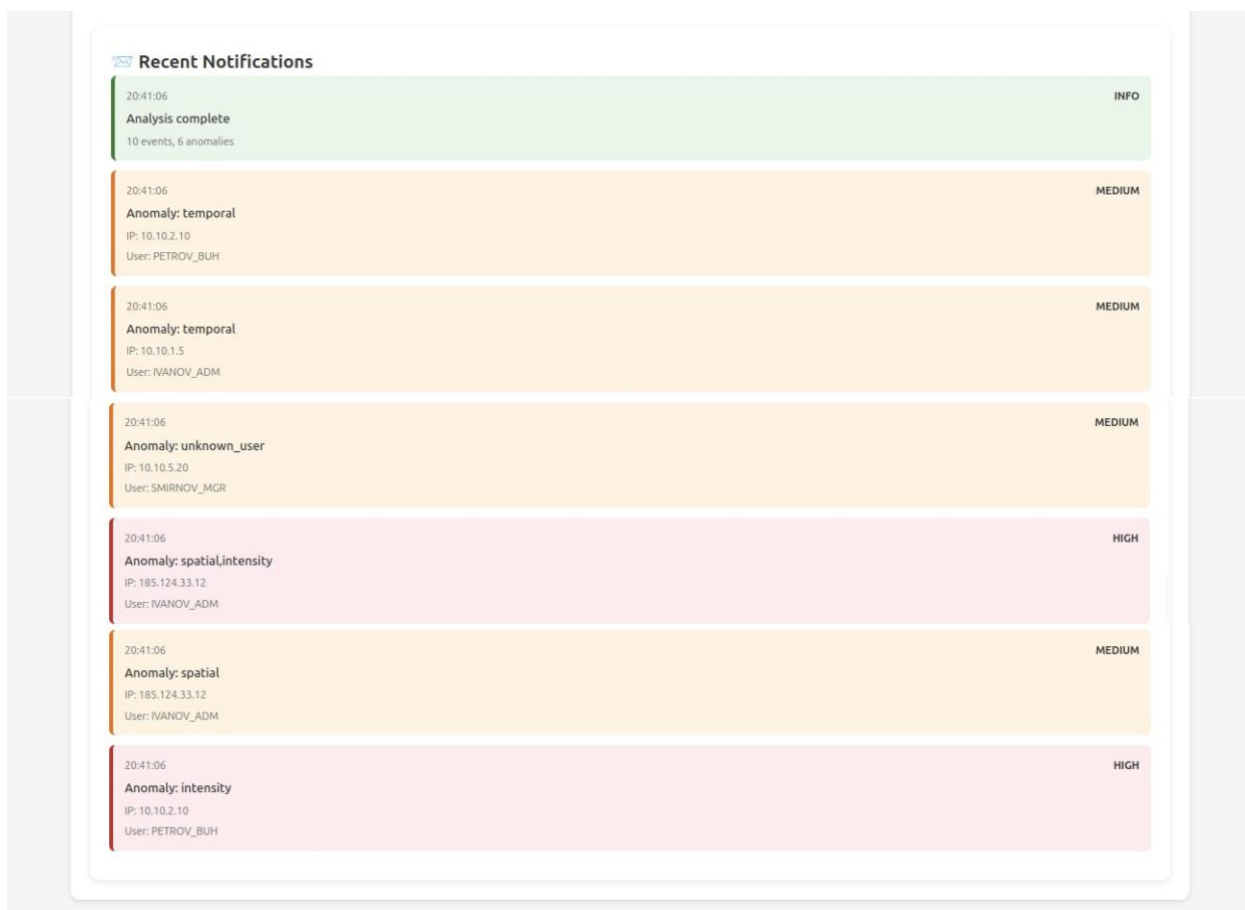


Рисунок Б.6. Панель уведомлений с цветовой индикацией событий

Для обеспечения комфортной работы в различных условиях освещения реализована поддержка двух режимов отображения: светлого и тёмного. Переключение между режимами осуществляется нажатием на кнопку, расположенную в правом верхнем углу экрана. В тёмном режиме все элементы интерфейса (панели, таблицы, графики, уведомления) адаптируют цветовую гамму, при этом сохраняется цветовая индикация уровней критичности аномалий.

Общий вид приложения в тёмном режиме представлен на рисунке Б.7. Демонстрация адаптации графических компонентов к тёмной теме приведена на рисунке Б.8.




Рисунок Б.7. Интерфейс приложения в тёмном режиме




Рисунок Б.8. Аналитические графики в тёмном режиме

Результаты тестирования.

При тестировании на синтетическом датасете (таблица 3.2) получены следующие результаты:

- обработано 10 событий;
- построены профили для 3 пользователей;
- обнаружено 6 аномалий различной степени критичности;
- реализована разметка событий и сохранение обратной связи.

Время обработки файла — менее 1 секунды, что подтверждает возможность работы в режиме реального времени.

Программная реализация и доступ к приложению.

Все компоненты приложения опубликованы в открытом репозитории на GitHub: <https://github.com/Jane-byte-der/diploma-AI-security-platform/> (папка ai-security-platform/). Репозиторий содержит полный исходный код, включая серверную и клиентскую части, а также синтетические данные для тестирования.

Для обеспечения удалённого доступа приложение было развёрнуто на облачной платформе Render.com. В процессе развёртывания была выполнена настройка среды выполнения: зафиксирована версия Python 3.12.8, установлены необходимые зависимости согласно требованиям проекта, сконфигурированы команды сборки и запуска. Приложение функционирует в режиме веб-сервиса и обрабатывает запросы пользователей аналогично локальной версии.

Развёрнутая версия веб-интерфейса доступна для тестирования по постоянной ссылке: <https://diploma-ai-security.onrender.com>

ПРИЛОЖЕНИЕ В

Описание репозитория с материалами выпускной квалификационной работы

Репозиторий содержит все материалы, использованные при выполнении практической части выпускной квалификационной работы (Глава 3). Все файлы структурированы по функциональному назначению и доступны в открытом виде.

1. Основные файлы проекта.

Тип файла	Имя файла	Назначение
Основной файл	analysis_diploma.ipynb	Jupyter Notebook с полным кодом анализа данных, построением профилей пользователей, выявлением аномалий и визуализацией результатов (соответствует разделам 3.2 и 3.3 диплома).
Документация	README.md	Полное описание репозитория на русском и английском языках, включающее: инструкции по запуску Jupyter Notebook и веб-приложения, таблицы с результатами внедрения, графики, примеры данных, описание архитектуры веб-приложения, его функциональных возможностей и результатов тестирования, а также скриншоты работающего интерфейса.
Служебный	.gitignore	Служебный файл Git, указывающий, какие файлы не должны загружаться в репозиторий (например, виртуальное окружение venv/, временные файлы).
Зависимости	requirements.txt	Список Python-библиотек, необходимых для запуска проекта (pandas, matplotlib, numpy).

Таблица В.1

2. Графические материалы.

Тип файла	Имя файла	Назначение
График	comparison_chart.png	График сравнения эффективности работы системы информационной безопасности до и после внедрения ИИ (используется в README.md).
График	jupyter_analysis.png	Дополнительные графики визуализации, полученные в ходе анализа в Jupyter Notebook.

Таблица В.2

3. Вспомогательные скрипты.

Тип файла	Имя файла	Назначение
Скрипт	create_chart.py	Python-скрипт для генерации графика comparison_chart.png.

Таблица В.3

4. Компоненты веб-приложения.

Тип файла	Имя файла	Назначение
Бэкенд	backend/app.py	Главный файл Flask-приложения, обрабатывающий HTTP-запросы
Модуль	backend/anomaly_detector.py	Ядро системы обнаружения аномалий (алгоритмы из главы 3)
Модуль	backend/profile_generator.py	Кластеризация пользователей для построения типовых профилей
Модуль	backend/database.py	Работа с базой данных SQLite для хранения обратной связи
Служебный	backend/__init__.py	Обеспечивает корректную работу относительных импортов, маркирует директорию backend как пакет Python
Фронтенд	frontend/templates/index.html	HTML-шаблон пользовательского интерфейса
Данные	data/sample_logs.csv	Синтетический датасет для тестирования (таблица 3.2)
Конфигурация	runtime.txt	Фиксация версии Python (3.12.8) для развертывания

Зависимости	requirements.txt	Список библиотек для веб-приложения (Flask, pandas, numpy, scikit-learn, matplotlib, gunicorn)
--------------------	------------------	--

Таблица В.4

Краткое описание процесса работы:

1. Создание виртуального окружения — изоляция зависимостей проекта.
2. Разработка кода в Jupyter Notebook — анализ синтетического датасета, построение профилей пользователей, выявление аномалий.
3. Разработка веб-приложения на Flask — создание интерактивного интерфейса (директория ai-security-platform/).
4. Генерация графиков — визуализация результатов (круговые диаграммы, столбчатые графики).
5. Подготовка документации — оформление README.md с таблицей и изображениями.
6. Инициализация Git-репозитория — отслеживание версий файлов.
7. Загрузка на GitHub — публикация проекта в открытом доступе по ссылке: <https://github.com/Jane-byte-der/diploma-AI-security->.
8. Развертывание на платформе Render.com — обеспечение удаленного доступа к веб-приложению.
9. Проверка работоспособности — тестирование доступности и корректности работы на различных устройствах и в разных браузерах.